

Influencia de la carga competitiva acumulada en el rendimiento de tenistas profesionales

Diego García Alba

dirigido por
Manuel Ceballos

Trabajo Fin de Grado
Grado en Matemática Aplicada



Universidad Loyola Andalucía
Curso: 2026 – 2027

Influencia de la carga competitiva acumulada en el rendimiento de tenistas profesionales

Diego García Alba

Dirigido por:
Manuel Ceballos

Resumen

Este Trabajo de Fin de Grado estudia si la carga competitiva acumulada externa observable aporta información útil para mejorar la predicción del rendimiento de tenistas profesionales. Para ello, se utilizaron datos históricos del circuito ATP en una estructura jugador-partido, tomando como variable objetivo el porcentaje de juegos ganados. A partir del historial competitivo se construyeron variables relacionadas con el volumen de juegos y torneos disputados, la participación anterior, el tiempo entre participaciones y la densidad competitiva reciente. Estas variables se incorporaron a un modelo base formado por predictores tradicionales del jugador, del rival y del contexto del encuentro. La comparación se realizó mediante validación temporal, utilizando el MAE como métrica principal para comprobar si la incorporación de la carga mejoraba la predicción y reservando la temporada 2024 para la evaluación final. XGBoost obtuvo el menor MAE medio durante la validación interna, con resultados muy similares a HistGradientBoosting y LightGBM. En 2024, el modelo ampliado con una ventana de 365 días redujo el MAE aproximadamente un 1,40 % respecto al modelo base y aumentó el R^2 de 0,1212 a 0,1399. La mejora también se mantuvo al cambiar el algoritmo, utilizar una ventana de 180 días y aplicar *bootstrap*. En conjunto, los resultados indican que la carga competitiva acumulada externa observable aporta información predictiva adicional, aunque su contribución es reducida y no permite establecer una relación causal con el rendimiento.

Palabras clave: tenis profesional, carga competitiva acumulada, rendimiento deportivo, aprendizaje automático, modelización predictiva.

Influence of Accumulated Competition Load on the Performance of Professional Tennis Players

Diego García Alba

Supervised by:
Manuel Ceballos

Abstract

This Bachelor’s Thesis studies whether accumulated external competition load, measured using observable competition data, provides useful information for improving the prediction of performance in professional tennis players. Historical ATP data were used in a player–match structure, with the percentage of games won as the target variable. Different variables were constructed from competition history, including the number of games and tournaments played, the previous tournament participation, the time between participations, and recent competition density. These variables were added to a baseline model based on traditional predictors related to the player, the opponent, and match context. The models were compared using temporal validation, with MAE as the main metric for assessing whether the addition of competition-load variables improved predictive performance, while the 2024 season was reserved for the final evaluation. XGBoost achieved the lowest mean MAE during internal validation, with results very similar to HistGradient-Boosting and LightGBM. In 2024, the expanded model using a 365-day window reduced MAE by approximately 1.40% compared with the baseline model and increased R^2 from 0.1212 to 0.1399. The improvement was also maintained when changing the algorithm, using an alternative 180-day window, and applying bootstrap resampling. Overall, the results indicate that accumulated external competition load provides additional predictive information, although its contribution is modest and does not allow a causal relationship with performance to be established.

Keywords: professional tennis, accumulated competition load, sports performance, machine learning, predictive modelling.

Índice general

1. Introducción	1
2. Estado del arte	3
2.1. Modelización del rendimiento deportivo	3
2.2. Predicción y análisis del rendimiento en tenis profesional	4
2.3. Variables utilizadas en la predicción del rendimiento tenístico	5
2.4. Carga competitiva acumulada, fatiga y recuperación en tenis	6
2.5. Limitaciones de los trabajos previos y justificación del estudio	7
3. Fundamentos teóricos	8
3.1. Modelización estadística y aprendizaje supervisado	8
3.2. Asociación, predicción y causalidad	9
3.3. Variable objetivo y formulación como problema de regresión	10
3.4. Asociación, dependencia y redundancia entre variables	11
3.4.1. Medidas de asociación: Pearson, Spearman y Kendall	11
3.4.2. Información mutua y dependencias no lineales	13
3.4.3. Redundancia, multicolinealidad y agrupación de predictores	14
3.5. Modelos predictivos considerados	16
3.5.1. Modelo lineal y regresión Ridge	16
3.5.2. Árboles de decisión, Random Forest y Extra Trees	17
3.5.3. Gradient Boosting, HistGradientBoosting, XGBoost y LightGBM	19
3.6. Generalización, validación temporal y selección de modelos	21
3.7. Métricas de evaluación	22
3.8. Aportación incremental, incertidumbre e interpretabilidad	23
4. Diseño del estudio y construcción de la base de datos	25
4.1. Origen de los datos	25
4.2. Periodo temporal de estudio	26
4.3. Transformación de la estructura de los partidos	27
4.4. Definición de la variable objetivo	28
4.5. Construcción y preparación de los predictores tradicionales	29
4.5.1. Clasificación funcional de las variables	30
4.5.2. Conjunto inicial de variables predictivas	30
4.5.3. Tratamiento de las variables categóricas	31
4.6. Construcción de las variables de carga competitiva acumulada	33
4.6.1. Definición operacional y alcance de la carga competitiva observable	33

4.6.2.	Unidad temporal y transformación a los niveles jugador–torneo y jugador–fecha	35
4.6.3.	Construcción del historial competitivo previo y separación de bloques temporales	36
4.6.4.	Construcción de las ventanas temporales de carga	39
4.6.5.	Variables de la participación anterior, separación temporal y densidad competitiva reciente	41
4.6.6.	Validación temporal y comprobación de las variables construidas . .	44
5.	Análisis exploratorio y selección de variables	46
5.1.	Distribución, valores ausentes y calidad de los datos	47
5.1.1.	Predictores tradicionales	47
5.1.2.	Variables de carga competitiva	47
5.2.	Asociación con la variable de rendimiento	48
5.2.1.	Predictores tradicionales	48
5.2.2.	Variables de carga competitiva	49
5.3.	Dependencia y redundancia entre predictores	52
5.3.1.	Predictores tradicionales	52
5.3.2.	Variables de carga competitiva	53
5.4.	Información mutua respecto al rendimiento	57
5.5.	Selección final de variables	58
5.5.1.	Selección de los predictores del modelo base	59
5.5.2.	Selección de las variables de carga competitiva	60
5.5.3.	Conjuntos finales para la modelización	62
6.	Modelización y resultados	66
6.1.	Estrategia de modelización y validación temporal	67
6.2.	Comparación y selección de modelos	68
6.3.	Aportación incremental de las variables de carga competitiva	72
6.3.1.	Robustez frente a la elección del algoritmo	75
6.3.2.	Robustez frente al horizonte temporal	75
6.4.	Evaluación temporal externa en 2024	77
6.4.1.	Incertidumbre de la mejora predictiva	80
6.5.	Interpretabilidad del modelo final	82
6.6.	Estabilidad de la mejora según la superficie	84
6.7.	Coherencia de las predicciones del modelo final	85
7.	Discusión	87
7.1.	Interpretación de los principales resultados	87
7.2.	Interpretación de la carga competitiva y relación con la literatura	88
7.3.	Robustez y relevancia práctica de la mejora	88
7.4.	Limitaciones del estudio	89
7.5.	Implicaciones y líneas futuras	90
8.	Conclusiones	92

A. Anexos	94
A.1. Definición de variables	94
A.2. Resultados complementarios	98
A.3. Código empleado	103
A.4. Declaración de autoría y uso de inteligencia artificial	104

Índice de figuras

3.1. Esquemas conceptuales de <i>bagging</i> y <i>gradient boosting</i> . Adaptado de las Figuras 1 y 2 de Mienye y Sun [22] (CC BY 4.0).	19
4.1. Esquema de construcción de las variables de carga competitiva.	44
5.1. Correlaciones de Spearman de las cargas absolutas y de las diferencias jugador-rival con el porcentaje de juegos ganados.	51
5.2. Agrupación jerárquica de las variables de carga competitiva basada en la correlación de Spearman. La línea discontinua indica el corte orientativo de distancia 0,20.	54
5.3. Asociación de los principales predictores tradicionales con el porcentaje de juegos ganados: correlaciones de Spearman del jugador y variables contextuales con mayor información mutua.	58
6.1. Reducción relativa del MAE respecto a la referencia basada en la media en la comparación inicial. La línea discontinua indica el rendimiento de la referencia basada en <code>diff_ranking</code>	70
6.2. Reducción relativa del MAE de las especificaciones Principal y Ampliada respecto al modelo Base en cada <i>fold</i> temporal de XGBoost-365d.	73
6.3. Reducción relativa del MAE de las especificaciones Principal y Ampliada respecto al modelo Base en la evaluación temporal externa de 2024 para la familia de 365 días.	79
6.4. Incremento de R^2 , expresado en puntos porcentuales, de las especificaciones Principal y Ampliada respecto al modelo Base en la evaluación temporal externa de 2024 para la familia de 365 días.	79
6.5. Mejora del MAE e intervalos <i>bootstrap</i> del 95 % en la evaluación temporal externa de 2024.	81
6.6. Importancia por permutación de las variables diferenciales de carga competitiva y de ranking en el modelo ampliado XGBoost-365d.	83
6.7. Valores observados frente a predicciones del modelo ampliado XGBoost-365d en la evaluación temporal externa de 2024. La intensidad de las celdas representa el número de observaciones y la línea discontinua corresponde a la recta de identidad $y = x$	85
A.1. Distribución del intervalo entre inicios competitivos antes y después de la transformación logarítmica.	98

Índice de cuadros

5.1. Variables de carga competitiva seleccionadas para la modelización.	62
5.2. Especificaciones definidas para la modelización.	64
6.1. Rendimiento medio de los modelos optimizados durante la validación temporal interna.	71
6.2. Análisis de ablación de las variables de carga en la especificación ampliada de 365 días.	74
6.3. MAE medio de las principales especificaciones durante la validación temporal interna.	77
6.4. Resultados de la evaluación temporal externa sobre la temporada 2024. . .	78
A.1. Variable objetivo, predictores tradicionales y control temporal utilizados en la modelización.	94
A.2. Definición y unidades de las variables de carga competitiva utilizadas en la modelización.	96
A.3. Diagnóstico de colinealidad de las variables relativas de carga competitiva. .	98
A.4. Principales dependencias entre las variables de carga según medidas complementarias.	99
A.5. Rendimiento de las especificaciones Base y Ampliada de XGBoost-365d según la superficie en la evaluación temporal externa de 2024.	99
A.6. Espacios de búsqueda utilizados durante la optimización de hiperparámetros.	100
A.7. Hiperparámetros seleccionados durante la validación temporal interna. . . .	101
A.8. Resumen de la estabilidad temporal de las principales decisiones de selección.	102

Capítulo 1

Introducción

En los últimos años, el análisis de datos y las técnicas de aprendizaje automático han adquirido una relevancia creciente en el deporte profesional. La disponibilidad de información procedente de competiciones oficiales ha permitido desarrollar herramientas para analizar el rendimiento de los deportistas, identificar patrones asociados a la competición y construir modelos orientados a la predicción de resultados futuros.

En este contexto, el tenis constituye un entorno especialmente interesante para la aplicación de estas metodologías. Se trata de un deporte individual en el que cada partido enfrenta directamente a dos jugadores bajo unas condiciones competitivas concretas, como la superficie, la ronda, la categoría del torneo o el formato del encuentro. Además, cada partido genera información estadística detallada que puede ser utilizada para analizar el rendimiento desde una perspectiva cuantitativa.

Tradicionalmente, los modelos predictivos en tenis se han centrado en estimar el resultado final de un partido, normalmente a partir de variables relacionadas con el ranking de los jugadores, sus características individuales, el contexto del torneo o sus resultados previos [33, 13]. Sin embargo, el rendimiento deportivo es un fenómeno complejo que puede estar relacionado con factores que evolucionan a lo largo de la temporada y que no siempre quedan reflejados en las variables tradicionales.

Entre estos factores se encuentra la carga competitiva acumulada, entendida en este trabajo como la actividad competitiva previa que puede reconstruirse a partir del historial de partidos de cada jugador. Esta exposición se representa mediante el volumen de juegos, sets y partidos disputados, la frecuencia de participación en torneos, la separación temporal entre inicios competitivos y la distribución de la actividad durante las semanas anteriores. En un deporte individual como el tenis, estas características del historial competitivo pueden contener información relevante sobre el estado competitivo previo del jugador y su rendimiento posterior.

El objetivo general de este Trabajo de Fin de Grado es evaluar si la incorporación de variables de carga competitiva externa observable aporta capacidad predictiva adicional en el análisis del rendimiento de tenistas profesionales. Para ello, se utiliza una base de datos histórica de partidos del circuito ATP (Association of Tennis Professionals), transformada a una estructura jugador-partido en la que cada observación representa el rendimiento de un jugador frente a un rival en un encuentro determinado.

El rendimiento se cuantifica mediante el porcentaje de juegos ganados por el jugador en el partido. A partir de esta estructura, se comparará un modelo base compuesto principalmente por predictores tradicionales disponibles antes del encuentro con modelos ampliados que incorporen variables construidas a partir de la actividad competitiva previa de ambos jugadores. La comparación se realizará mediante una estrategia de validación temporal, con el objetivo de determinar si estas variables mejoran la capacidad de generalización fuera de la muestra utilizada para desarrollar los modelos.

Capítulo 2

Estado del arte

2.1. Modelización del rendimiento deportivo

El estudio del rendimiento deportivo ha experimentado una evolución significativa durante las últimas décadas gracias al desarrollo de las tecnologías de registro y almacenamiento de datos. La creciente disponibilidad de información procedente de competiciones profesionales ha permitido complementar los enfoques tradicionales basados en la observación con metodologías fundamentadas en el análisis cuantitativo.

En este contexto, la modelización del rendimiento deportivo se ha consolidado como una herramienta útil para estudiar los factores relacionados con el desempeño de deportistas y equipos. Las técnicas estadísticas y computacionales permiten analizar grandes volúmenes de información, identificar patrones y evaluar la relación entre distintas variables y el rendimiento observado.

El objetivo de estos modelos no se limita únicamente a la predicción de resultados futuros. Además de su capacidad predictiva, permiten obtener información sobre la importancia relativa de los distintos factores que intervienen en la competición, facilitando así una mejor comprensión del fenómeno deportivo y apoyando la toma de decisiones en entornos profesionales.

La aplicación de este tipo de metodologías se ha extendido progresivamente a disciplinas deportivas muy diversas, dando lugar al desarrollo de un área de investigación

conocida como *Sports Analytics*. Dentro de este ámbito, los modelos predictivos han demostrado ser herramientas útiles para estudiar el rendimiento competitivo y analizar la relación de factores técnicos, físicos, tácticos y contextuales con el resultado deportivo.

En el tenis profesional, el análisis basado en datos permite desarrollar modelos predictivos a partir de la información histórica de los jugadores y del contexto competitivo [33, 13].

2.2. Predicción y análisis del rendimiento en tenis profesional

El tenis profesional constituye uno de los entornos más estudiados dentro del análisis predictivo aplicado al deporte. La naturaleza individual de la competición, la existencia de rankings oficiales y la amplia disponibilidad de datos históricos convierten a este deporte en un escenario especialmente adecuado para el desarrollo de modelos estadísticos y de aprendizaje automático.

Tradicionalmente, gran parte de la literatura se ha centrado en la predicción del resultado de los partidos, estimando la probabilidad de victoria de un jugador frente a un rival determinado. Para ello se han desarrollado diferentes enfoques, desde modelos estadísticos clásicos basados en comparaciones por pares, como los modelos Bradley-Terry, hasta sistemas de valoración dinámica como Elo o Glicko, diseñados para estimar la fuerza competitiva de los jugadores a lo largo del tiempo [33].

Con el aumento de la disponibilidad de datos y la capacidad computacional, han surgido trabajos que incorporan técnicas de aprendizaje automático para mejorar la precisión de las predicciones. Estos modelos utilizan información histórica de los jugadores y del contexto competitivo para identificar patrones asociados al rendimiento y al resultado de los encuentros [31].

Además del resultado final, los modelos pueden incorporar información más detallada sobre el rendimiento previo y el nivel de los jugadores, como estadísticas históricas o sistemas dinámicos de valoración. Estas variables permiten representar con mayor detalle

el estado competitivo antes del encuentro, aunque el objetivo de muchos trabajos siga siendo predecir al ganador [33, 13, 31].

En conjunto, la literatura muestra que el tenis constituye un campo de investigación consolidado dentro del análisis predictivo deportivo. Sin embargo, existe una gran diversidad en las variables utilizadas y en la forma de representar el rendimiento, lo que continúa generando nuevas líneas de investigación orientadas a mejorar la capacidad explicativa y predictiva de los modelos [33, 13].

2.3. Variables utilizadas en la predicción del rendimiento tenístico

La capacidad predictiva de un modelo depende en gran medida de las variables utilizadas para representar el estado competitivo de los jugadores antes de un partido. Por este motivo, una parte importante de la investigación en tenis se ha centrado en identificar qué factores aportan mayor información sobre el rendimiento y el resultado de los encuentros.

Entre las variables más utilizadas destacan aquellas relacionadas con el nivel competitivo del jugador. El ranking ATP y otros sistemas de valoración similares constituyen algunos de los indicadores más empleados en la literatura, ya que permiten aproximar la fuerza relativa de los jugadores y han mostrado una elevada utilidad predictiva [33, 13].

Además de la calidad individual del jugador, numerosos estudios incorporan variables asociadas al contexto competitivo. Entre ellas destacan la superficie de juego, la ronda del torneo, la categoría de la competición o el formato del encuentro. Estas variables permiten representar las condiciones específicas bajo las que se disputa cada partido y pueden estar asociadas al rendimiento observado o aportar información útil para su predicción [33].

Otra línea habitual de investigación consiste en incorporar características propias de los jugadores, como la edad, la altura o determinadas métricas históricas de rendimiento. Asimismo, muchos modelos consideran información del rival, ya que el rendimiento de un jugador no puede entenderse de forma aislada, sino en relación con el nivel competitivo del oponente al que se enfrenta.

En conjunto, la literatura muestra que el rendimiento en tenis es un fenómeno multifactorial en el que intervienen tanto características individuales como variables contextuales. Por ello, los modelos predictivos suelen combinar información del jugador, del rival y del entorno competitivo con el objetivo de obtener una representación más completa del partido antes de su disputa [33, 13].

2.4. Carga competitiva acumulada, fatiga y recuperación en tenis

La carga competitiva acumulada puede entenderse como la exposición derivada de la participación continuada en competiciones a lo largo del tiempo. En el contexto del tenis profesional, esta exposición puede aproximarse mediante el volumen y la distribución temporal de la actividad competitiva previa [20]. En el presente trabajo, esta exposición se representa mediante el número de partidos, juegos y sets disputados, la frecuencia de participación en torneos y la separación temporal entre participaciones. Estas medidas se interpretan como indicadores de carga competitiva externa observable, sin incorporar información sobre entrenamientos ni cuantificar directamente la fatiga fisiológica o la recuperación individual [4].

La literatura científica ha señalado que el tenis es un deporte con elevadas exigencias físicas y fisiológicas. Los jugadores deben afrontar esfuerzos intermitentes de alta intensidad y demandas prolongadas durante la competición. Como consecuencia, la fatiga puede manifestarse durante el propio encuentro y entre partidos sucesivos, especialmente cuando los periodos de recuperación son reducidos [24].

Diversos estudios han analizado la relación entre competición, fatiga y recuperación en jugadores de tenis. Reid y Duffield describen alteraciones fisiológicas, neuromusculares y perceptivas asociadas a partidos prolongados y a la disputa de encuentros en días consecutivos, aunque señalan que la evidencia sobre su efecto directo en el rendimiento posterior sigue siendo limitada [24].

Desde una perspectiva longitudinal, Kovalchik estudió la carga competitiva acumulada en tenistas profesionales utilizando los juegos disputados como medida de carga externa y analizó su relación con periodos posteriores de ausencia competitiva [20].

En conjunto, estas investigaciones justifican estudiar el historial competitivo previo como una posible fuente de información sobre el estado competitivo del jugador. Sin embargo, no permiten asumir que una mayor carga produzca necesariamente un empeoramiento posterior del rendimiento.

2.5. Limitaciones de los trabajos previos y justificación del estudio

A pesar de los avances alcanzados en la modelización del rendimiento y la predicción de partidos de tenis, todavía existen aspectos que continúan abiertos a investigación.

Los trabajos revisados muestran dos enfoques cercanos, pero diferentes. Por un lado, los modelos predictivos en tenis utilizan principalmente variables como el ranking, la superficie o el rendimiento histórico, aunque existen propuestas que incorporan indicadores contruidos de fatiga previa [33, 13, 31]. Por otro, Kovalchik [20] analiza la carga competitiva acumulada en relación con periodos posteriores de ausencia. En cambio, está menos desarrollado el estudio de si un bloque específico de carga competitiva externa observable mejora la predicción del rendimiento una vez consideradas las variables tradicionales.

Por este motivo, el presente trabajo analiza si la incorporación de estas variables aporta capacidad predictiva adicional al estimar el rendimiento de tenistas profesionales.

Capítulo 3

Fundamentos teóricos

Este capítulo presenta los principales fundamentos estadísticos y de aprendizaje automático necesarios para comprender los análisis desarrollados posteriormente. Se introducen los conceptos relacionados con la asociación y dependencia entre variables, los modelos predictivos considerados, la estrategia de validación y las medidas utilizadas para evaluar e interpretar su rendimiento.

3.1. Modelización estadística y aprendizaje supervisado

La modelización estadística permite estudiar cómo se relaciona una variable de interés con un conjunto de variables que pueden ayudar a explicarla o predecirla. Si Y representa la variable objetivo y $X_1, \dots, X_p$ los predictores disponibles, esta relación puede expresarse de forma general como [17]:

$$Y = f(X_1, \dots, X_p) + \varepsilon,$$

donde f representa la relación existente entre los predictores y la variable objetivo, mientras que ε recoge aquella parte del comportamiento de Y que el modelo no puede explicar mediante las variables disponibles.

En un problema de aprendizaje supervisado se dispone, para cada observación, tanto de los predictores como del valor conocido de la variable objetivo. A partir de esta información, el modelo intenta aproximar la función desconocida f mediante una función estimada $\hat{f}$. Una vez ajustado el modelo, para una nueva observación $\mathbf{x}$ puede obtenerse una predicción mediante:

$$\hat{y} = \hat{f}(\mathbf{x}).$$

No todos los modelos representan esta relación de la misma forma. Algunos imponen estructuras más sencillas, mientras que otros permiten recoger relaciones no lineales e interacciones entre variables. Sin embargo, utilizar un modelo más complejo no garantiza necesariamente mejores predicciones sobre datos nuevos. Por este motivo, además de ajustar el modelo a la información disponible, resulta fundamental comprobar posteriormente su capacidad para generalizar a observaciones que no hayan intervenido durante el entrenamiento [17].

En este trabajo, este enfoque se utiliza para estudiar el rendimiento de los jugadores a partir de información disponible antes de cada partido. Dado que la variable objetivo es cuantitativa, el problema predictivo se plantea como una tarea de regresión supervisada, concepto que se desarrolla posteriormente.

3.2. Asociación, predicción y causalidad

Cuando se analiza la relación entre distintas variables es importante diferenciar entre asociación, capacidad predictiva y causalidad. Aunque estos conceptos están relacionados, no significan lo mismo y deben interpretarse de forma diferente.

Una asociación estadística indica que dos variables presentan algún tipo de relación en los datos observados. Por ejemplo, una variable puede aumentar o disminuir de forma habitual cuando cambia otra. Sin embargo, que exista esta relación no significa necesariamente que una variable sea la causa de la otra. Pueden existir otros factores que influyan

sobre ambas y expliquen, al menos parcialmente, la asociación observada. Por este motivo, identificar una relación estadística no es suficiente para establecer una relación causal [14].

La utilidad predictiva responde a una pregunta diferente. En este caso, el interés se centra en comprobar si disponer de una determinada variable ayuda a realizar mejores predicciones sobre observaciones nuevas. Una variable puede presentar una asociación individual pequeña con la variable objetivo y, aun así, resultar útil cuando se combina con otros predictores. Esto puede ocurrir, por ejemplo, cuando existen relaciones no lineales o interacciones entre variables. Del mismo modo, una variable con una asociación elevada puede aportar poca información adicional si su contenido ya está representado por otros predictores del modelo [17].

Esta diferencia es especialmente importante en este trabajo, ya que posteriormente se estudia tanto la asociación de distintas variables con el rendimiento como su aportación dentro de los modelos predictivos. El objetivo es determinar si determinada información permite mejorar la predicción del rendimiento una vez consideradas conjuntamente las demás características disponibles. Por tanto, las relaciones encontradas y la utilidad predictiva de las variables deben interpretarse como evidencia estadística y predictiva, y no como una demostración de que dichas variables causen directamente cambios en el rendimiento [14, 30].

3.3. Variable objetivo y formulación como problema de regresión

En aprendizaje supervisado, la elección entre regresión y clasificación depende de la naturaleza de la variable objetivo. Los problemas de regresión trabajan con respuestas cuantitativas, mientras que los problemas de clasificación buscan asignar cada observación a una categoría [17].

En este trabajo, la variable objetivo es el porcentaje de juegos ganados, una medida cuantitativa acotada en el intervalo:

$$0 \leq Y \leq 1.$$

El hecho de encontrarse entre 0 y 1 no convierte esta variable en una probabilidad ni en una respuesta binaria, ya que puede tomar distintos valores que representan diferentes niveles de rendimiento dentro del partido. Por este motivo, el problema principal se formula mediante regresión.

Algunos modelos de regresión no imponen de forma automática que sus predicciones permanezcan dentro del intervalo de la variable objetivo. Por ello, cuando se trabaja con una respuesta acotada resulta conveniente comprobar posteriormente que las estimaciones obtenidas sean coherentes con sus límites teóricos.

3.4. Asociación, dependencia y redundancia entre variables

Antes de construir un modelo predictivo resulta útil estudiar cómo se relacionan las variables disponibles. Por una parte, interesa analizar la asociación entre cada predictor y la variable objetivo para conocer qué tipo de relación existe entre ellos. Por otra, también es necesario estudiar las relaciones entre los propios predictores, ya que varias variables pueden contener información muy similar y aportar redundancia al conjunto de datos.

Para ello pueden utilizarse distintas medidas estadísticas, ya que no todas permiten detectar el mismo tipo de relación. En los apartados siguientes se presentan las principales herramientas empleadas posteriormente en este trabajo para estudiar asociaciones lineales y monótonas, dependencias más generales y posibles problemas de redundancia o multicolinealidad entre predictores.

3.4.1. Medidas de asociación: Pearson, Spearman y Kendall

Para estudiar la relación entre dos variables pueden utilizarse diferentes coeficientes de asociación. Cada uno resume un tipo de relación distinto, por lo que su elección depende de la estructura que se quiera analizar y de las características de los datos.

El coeficiente de correlación de Pearson mide el grado de asociación lineal entre dos variables cuantitativas. Se define como:

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y},$$

donde $\text{Cov}(X, Y)$ representa la covarianza entre ambas variables y σ_X y σ_Y sus desviaciones típicas. El coeficiente toma valores entre -1 y 1 . Un valor positivo indica que ambas variables tienden a variar en la misma dirección, mientras que un valor negativo indica una relación inversa. Valores próximos a cero indican ausencia de una relación lineal clara, aunque no permiten concluir que las variables sean independientes [28].

Cuando la relación entre las variables no tiene por qué ser lineal, puede resultar útil emplear medidas basadas en el orden de las observaciones. El coeficiente de Spearman se obtiene calculando la correlación entre los rangos de ambas variables:

$$\rho_s = \text{corr}(R_X, R_Y),$$

donde R_X y R_Y representan los rangos asociados a X e Y . De este modo, Spearman permite estudiar relaciones monótonas, es decir, situaciones en las que una variable tiende a aumentar o disminuir cuando lo hace la otra, aunque la relación no siga necesariamente una línea recta. Al trabajar con rangos, también resulta menos sensible que Pearson a valores extremos [28].

El coeficiente de Kendall también utiliza el orden de las observaciones, pero se basa en comparar pares. Dos observaciones forman un par concordante cuando el orden de una variable coincide con el de la otra y un par discordante cuando ocurre lo contrario. En presencia de empates puede utilizarse la versión τ_b , que introduce una corrección para tenerlos en cuenta [6].

Si C representa el número de pares concordantes, D el número de pares discordantes y T_X y T_Y los pares empatados únicamente en cada una de las variables, el coeficiente puede expresarse como:

$$\tau_b = \frac{C - D}{\sqrt{(C + D + T_X)(C + D + T_Y)}}.$$

Pearson, Spearman y Kendall aportan, por tanto, información complementaria. Pearson se centra en relaciones lineales, mientras que Spearman y Kendall analizan principalmente el orden de las observaciones. Su utilización conjunta permite comprobar si una asociación se mantiene al analizarla desde perspectivas estadísticas diferentes, sin interpretar ninguno de estos coeficientes como una prueba de causalidad.

3.4.2. Información mutua y dependencias no lineales

Las medidas de correlación permiten estudiar relaciones lineales o monótonas entre variables, pero no siempre son suficientes para identificar dependencias más complejas. Para complementar este análisis puede utilizarse la información mutua (MI), una medida procedente de la teoría de la información que cuantifica hasta qué punto conocer una variable aporta información sobre otra [21].

Para dos variables continuas X e Y , la información mutua puede expresarse como:

$$I(X; Y) = \int \int p(x, y) \log \left(\frac{p(x, y)}{p(x)p(y)} \right) dx dy,$$

donde $p(x, y)$ representa la función de densidad conjunta de ambas variables y $p(x)$ y $p(y)$ sus densidades marginales. La información mutua toma valores no negativos y, teóricamente, es igual a cero cuando las variables son independientes.

A diferencia de los coeficientes de correlación anteriores, la información mutua permite detectar relaciones más generales entre dos variables, aunque estas no sean lineales ni monótonas. Sin embargo, esta medida no indica la dirección de la relación. Por tanto, un valor elevado señala que existe una mayor dependencia entre las variables, pero no permite saber si una de ellas tiende a aumentar o disminuir cuando cambia la otra.

Cuando las variables son continuas, la información mutua debe estimarse a partir de los datos. Uno de los métodos utilizados para ello se basa en los vecinos más próximos,

utilizando la proximidad entre las observaciones para estimar la dependencia existente entre las variables. Como el resultado puede variar en función del método de estimación y de sus parámetros, sus valores deben interpretarse con cierta cautela y principalmente de forma comparativa.

Por último, una información mutua elevada no significa necesariamente que una variable sea importante dentro de un modelo predictivo. Dos predictores pueden estar muy relacionados entre sí y contener parte de la misma información. Por este motivo, la información mutua se utiliza como una medida complementaria y debe interpretarse junto con los análisis de asociación y redundancia entre variables.

Además de la información mutua, se utilizó la correlación de distancias (dCor) como una comprobación adicional de la dependencia entre variables. A diferencia de la correlación de Pearson, esta medida no se limita a relaciones lineales, por lo que puede detectar relaciones más complejas entre dos variables [32]. En este trabajo se utiliza únicamente como medida complementaria y no como criterio aislado para seleccionar predictores.

3.4.3. Redundancia, multicolinealidad y agrupación de predictores

Cuando varios predictores están muy relacionados entre sí, pueden contener información similar. En estos casos aparece redundancia, ya que añadir más variables no implica necesariamente incorporar información nueva y puede dificultar la interpretación del modelo.

Un caso particular es la multicolinealidad, que aparece cuando un predictor puede explicarse en gran medida mediante una combinación lineal de otros. Este problema es especialmente relevante en modelos lineales, donde puede aumentar la inestabilidad de los coeficientes. Sin embargo, la presencia de variables relacionadas no implica que deban eliminarse automáticamente, ya que su importancia depende del objetivo del análisis y del modelo utilizado [8].

Una de las medidas utilizadas para estudiar la multicolinealidad es el factor de inflación de la varianza o VIF:

$$\text{VIF}_j = \frac{1}{1 - R_j^2},$$

donde R_j^2 es el coeficiente de determinación obtenido al explicar el predictor X_j mediante el resto de variables. Cuanto mayor sea el VIF, mayor será su relación lineal con los demás predictores y mayor la inflación de la varianza asociada a su coeficiente en un modelo lineal. De forma complementaria, la tolerancia se define como:

$$T_j = 1 - R_j^2 = \frac{1}{\text{VIF}_j}.$$

Una tolerancia reducida indica, por tanto, una mayor colinealidad. Aunque existen valores orientativos para interpretar estas medidas, no deben utilizarse como reglas universales para eliminar variables [23].

La colinealidad también puede analizarse de forma conjunta mediante los índices de condición, que permiten detectar dependencias lineales en las que intervienen varias variables. Estos índices pueden complementarse con las proporciones de descomposición de la varianza para identificar qué predictores participan principalmente en dichas dependencias [8].

Otra forma de estudiar la redundancia es agrupar variables con comportamientos similares. La agrupación jerárquica forma progresivamente grupos a partir de una medida de distancia y permite representar su estructura mediante un dendrograma. En este trabajo se utiliza una medida de disimilitud basada en la correlación de Spearman:

$$d(X, Y) = 1 - |\rho_s(X, Y)|.$$

De este modo, dos variables muy correlacionadas en valor absoluto presentan una disimilitud pequeña y tienden a quedar agrupadas. El valor absoluto permite considerar como próximas tanto relaciones positivas como negativas de elevada intensidad.

En el enlace promedio, la distancia entre dos grupos se calcula a partir de la distancia media entre sus elementos. La correlación cofenética permite valorar hasta qué punto el dendrograma conserva las distancias originales entre las variables [27].

En conjunto, estas herramientas ayudan a detectar predictores que representan información similar y a realizar una selección de variables más razonada, evitando depender de una única medida estadística.

3.5. Modelos predictivos considerados

Existen diferentes métodos para abordar un problema de regresión y no todos representan de la misma forma la relación entre los predictores y la variable objetivo. Algunos parten de estructuras relativamente sencillas, como los modelos lineales, mientras que otros permiten recoger relaciones no lineales e interacciones mediante combinaciones de árboles de decisión.

En los apartados siguientes se presentan los fundamentos de las principales familias de modelos utilizadas posteriormente en este trabajo, comenzando por los modelos lineales regularizados y continuando con los métodos basados en árboles y los algoritmos de *gradient boosting*.

3.5.1. Modelo lineal y regresión Ridge

Uno de los enfoques más sencillos para un problema de regresión consiste en representar la variable objetivo mediante una combinación lineal de los predictores. Para p variables, la predicción puede expresarse como:

$$\hat{y} = \beta_0 + \sum_{j=1}^p \beta_j x_j,$$

donde β_0 representa el término independiente y cada coeficiente β_j recoge la contribución asociada al predictor x_j . Este tipo de modelo resulta sencillo de interpretar, aunque

su estructura puede ser limitada cuando existen relaciones no lineales o interacciones más complejas entre las variables [17].

La regresión Ridge parte del modelo lineal, pero incorpora una penalización sobre el tamaño de los coeficientes. Su estimación puede expresarse como:

$$\hat{\beta}^{\text{Ridge}} = \arg \min_{\beta} \left[\sum_{i=1}^n (y_i - \beta_0 - \mathbf{x}_i^T \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right],$$

donde el primer término mide el error de ajuste y el segundo penaliza coeficientes de gran magnitud. El parámetro $\lambda \geq 0$ controla la intensidad de esta penalización: cuando aumenta, los coeficientes tienden a reducirse hacia cero, aunque normalmente no llegan a anularse por completo [15].

Esta regularización puede resultar útil cuando existen predictores relacionados entre sí, ya que permite reducir la variabilidad de los coeficientes y obtener un modelo más estable. A cambio, se introduce cierto sesgo en la estimación, buscando un equilibrio entre el ajuste a los datos disponibles y la capacidad de generalización del modelo [15]. Dado que la penalización de Ridge depende de la magnitud de los coeficientes, la escala de los predictores puede influir en el ajuste. Por este motivo, cuando las variables presentan escalas diferentes resulta conveniente estandarizarlas [17], calculando los parámetros de la transformación únicamente a partir de los datos de entrenamiento [18].

3.5.2. Árboles de decisión, Random Forest y Extra Trees

Los árboles de decisión permiten construir modelos de regresión mediante divisiones sucesivas del conjunto de datos. En cada división se utiliza uno de los predictores para separar las observaciones en grupos cada vez más homogéneos respecto a la variable objetivo. El proceso genera una estructura formada por nodos y ramas hasta llegar a las hojas finales, donde se obtiene la predicción correspondiente a cada grupo.

Una de las principales ventajas de los árboles es que pueden representar relaciones no lineales e interacciones entre variables sin necesidad de especificarlas previamente. Sin embargo, un árbol individual puede adaptarse demasiado a los datos de entrenamiento y

presentar una elevada variabilidad ante pequeños cambios en la muestra. Una forma de reducir este problema consiste en combinar las predicciones de varios árboles mediante métodos de conjunto (*ensemble*) [17].

Random Forest construye un conjunto de árboles introduciendo aleatoriedad tanto en las observaciones utilizadas para entrenarlos como en los predictores considerados durante sus divisiones. Cada árbol se ajusta sobre una muestra obtenida con reemplazo y, en cada nodo, solo se considera una selección aleatoria de las variables disponibles. En problemas de regresión, la predicción final se obtiene promediando las predicciones de los distintos árboles [5]:

$$\hat{y}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}),$$


donde B representa el número de árboles y $T_b(\mathbf{x})$ la predicción realizada por el árbol b . Esta combinación permite obtener un modelo generalmente más estable que un único árbol, al reducir la dependencia de una estructura concreta de particiones.

Extra Trees sigue una idea similar, pero introduce un grado mayor de aleatoriedad durante la construcción de los árboles. Su principal diferencia es que los puntos de corte utilizados para dividir los nodos se seleccionan de forma aleatoria, en lugar de buscar siempre el mejor corte posible entre los candidatos. Esta mayor aleatoriedad puede reducir la variabilidad del modelo y también disminuir el coste de construcción de los árboles, aunque puede introducir un mayor sesgo [12].


Random Forest y Extra Trees pertenecen, por tanto, a la misma familia de modelos basados en la combinación de múltiples árboles. La diferencia principal se encuentra en el grado de aleatoriedad utilizado durante su construcción. Ambos permiten representar relaciones más flexibles que un modelo lineal.

3.5.3. Gradient Boosting, HistGradientBoosting, XGBoost y LightGBM

Los métodos de *gradient boosting* también combinan múltiples árboles de decisión, pero difieren de Random Forest y Extra Trees en la forma en que estos se construyen y relacionan entre sí. Como representación del aprendizaje *ensemble* en paralelo puede considerarse el esquema de *bagging*, en el que distintos modelos se ajustan de forma independiente y sus predicciones se agregan posteriormente. En cambio, el *gradient boosting* sigue una estrategia secuencial, en la que cada nuevo modelo se incorpora para reducir progresivamente la función de pérdida [11]. Ambos esquemas se ilustran en la Figura 3.1.



(a) Bagging: aprendizaje en paralelo.



(b) Gradient boosting: aprendizaje secuencial.

Figura 3.1: Esquemas conceptuales de *bagging* y *gradient boosting*. Adaptado de las Figuras 1 y 2 de Mienye y Sun [22] (CC BY 4.0).

En esta estrategia secuencial, la predicción final se construye de forma progresiva, incorporando en cada iteración la contribución de un nuevo modelo al conjunto ya existente. Esta idea puede formalizarse de manera general como:

$$F_M(x) = F_0(x) + \sum_{m=1}^M \eta h_m(x),$$

donde $F_0(x)$ representa la predicción inicial, $h_m(x)$ el árbol incorporado en la iteración m y η la tasa de aprendizaje. Este último parámetro controla cuánto contribuye cada nuevo árbol al modelo final. Un valor reducido permite realizar correcciones más pequeñas y progresivas, aunque normalmente requiere un mayor número de iteraciones [11].

El aprendizaje se guía mediante una función de pérdida que mide el error cometido por el modelo. En cada iteración se incorpora un nuevo árbol orientado a reducir dicha pérdida. De este modo, el *gradient boosting* puede representar relaciones no lineales e interacciones entre predictores, pero su flexibilidad también hace necesario controlar la complejidad del modelo para reducir el riesgo de sobreajuste.

HistGradientBoosting aplica este mismo principio utilizando una representación de los predictores mediante intervalos o *bins*. En lugar de considerar todos los valores posibles de una variable al buscar una división, se trabaja con un número más reducido de intervalos. Esto permite disminuir el número de posibles puntos de corte y hacer más eficiente la construcción de los árboles [29].

XGBoost es una implementación de *gradient boosting* diseñada para combinar capacidad predictiva, regularización y eficiencia computacional. Su función objetivo puede representarse de forma general como [7]:

$$\mathcal{L} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_k \Omega(f_k),$$

donde $l(y_i, \hat{y}_i)$ mide el error de predicción y $\Omega(f_k)$ penaliza la complejidad de los árboles incorporados al modelo. Además de esta regularización, XGBoost permite controlar aspectos como la profundidad de los árboles, la tasa de aprendizaje o la proporción de observaciones y predictores utilizados durante el entrenamiento.

LightGBM pertenece también a la familia de *gradient boosting* basado en árboles y utiliza técnicas orientadas a reducir el coste computacional durante el entrenamiento. Entre

sus características se encuentra el uso de histogramas para representar los predictores y una estrategia de crecimiento de los árboles centrada en las hojas que ofrecen una mayor reducción de la pérdida [19].

Por tanto, HistGradientBoosting, XGBoost y LightGBM comparten el principio general de construir el modelo de forma secuencial mediante árboles, pero utilizan diferentes estrategias para controlar su complejidad y mejorar la eficiencia del entrenamiento. Estas diferencias permiten comparar distintas implementaciones de una misma familia metodológica sin asumir que una de ellas deba ser necesariamente superior en todos los problemas.

3.6. Generalización, validación temporal y selección de modelos

El objetivo de un modelo predictivo no es únicamente ajustarse bien a los datos utilizados durante el entrenamiento, sino mantener un buen rendimiento sobre observaciones nuevas. Esta capacidad se conoce como generalización. Cuando un modelo se adapta en exceso a las particularidades de los datos de entrenamiento puede producirse sobreajuste o *overfitting*, reduciendo su rendimiento fuera de la muestra utilizada para ajustarlo [17].

Por este motivo, durante el desarrollo del modelo se separan los datos utilizados para entrenar de aquellos empleados para evaluar su comportamiento. La validación permite comparar modelos y seleccionar sus configuraciones, mientras que el conjunto de prueba debe mantenerse separado hasta la evaluación final, una vez tomadas las principales decisiones metodológicas.

Cuando los datos presentan una estructura temporal, esta separación debe respetar además su orden cronológico. Entrenar con observaciones futuras para evaluar periodos anteriores generaría un escenario poco realista y podría producir estimaciones demasiado optimistas. Una alternativa es utilizar una validación temporal con entrenamiento creciente, en la que el modelo se ajusta con la información disponible hasta un determinado momento y se evalúa posteriormente sobre un periodo futuro [25].

También debe evitarse la fuga de información o *data leakage*, que aparece cuando durante el desarrollo se utiliza información que no estaría disponible en el momento real de realizar una predicción. Esto puede ocurrir, por ejemplo, al incorporar datos futuros, utilizar el conjunto de prueba para tomar decisiones sobre el modelo o calcular transformaciones dependientes de los datos, como la imputación o la estandarización, utilizando información de validación o prueba. Asimismo, cuando existen observaciones estrechamente relacionadas, esta estructura debe respetarse en las particiones para evitar que información perteneciente a una misma unidad quede repartida entre entrenamiento y evaluación [18, 25].

Finalmente, los hiperparámetros son configuraciones del modelo que deben establecerse antes del ajuste definitivo. Su selección puede realizarse mediante procedimientos como la búsqueda en rejilla o la búsqueda aleatoria, comparando las diferentes configuraciones mediante el esquema de validación definido previamente [3].

3.7. Métricas de evaluación

El rendimiento de un modelo de regresión puede evaluarse comparando los valores observados con las predicciones obtenidas. En este trabajo se consideran tres métricas complementarias: MAE, RMSE y R^2 [17].

El error absoluto medio o MAE se define como:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|.$$

Esta métrica representa la magnitud media del error y se expresa en la misma escala que la variable objetivo, lo que facilita su interpretación. Valores menores indican una mayor precisión predictiva.

La raíz del error cuadrático medio o RMSE se calcula mediante:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}.$$

A diferencia del MAE, al elevar los errores al cuadrado penaliza con mayor intensidad las desviaciones de mayor magnitud.

Por último, el coeficiente de determinación R^2 compara el error del modelo con la variabilidad total de la variable objetivo:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

El R^2 evalúa el rendimiento del modelo en relación con una referencia basada en la media de la variable objetivo. Valores más elevados indican un mejor rendimiento relativo, mientras que un valor próximo a cero supone un comportamiento similar al de dicha referencia. En evaluación fuera de muestra, R^2 también puede tomar valores negativos cuando el error del modelo supera al obtenido utilizando la media como referencia. Las tres métricas aportan información diferente, por lo que su interpretación conjunta permite realizar una evaluación más completa del rendimiento predictivo.

3.8. Aportación incremental, incertidumbre e interpretabilidad

Cuando el objetivo es comprobar si un nuevo conjunto de variables aporta información útil, resulta conveniente comparar modelos que mantengan la misma estructura y difieran únicamente en los predictores incorporados. De este modo, la variación en las métricas puede utilizarse para valorar la aportación predictiva adicional de la nueva información.

Una forma complementaria de estudiar esta aportación es el análisis de ablación. Este procedimiento consiste en retirar una variable, volver a ajustar el modelo con los predictores restantes y evaluar de nuevo su rendimiento. Si su eliminación aumenta el error, puede considerarse que dicha variable aportaba información útil dentro del conjunto de predictores. Sin embargo, cuando existen variables relacionadas entre sí, una contribución individual reducida no implica necesariamente que la información representada por esa variable carezca de utilidad.

Además de observar la mejora obtenida, también es importante comprobar si esta se mantiene de forma estable. Para ello puede utilizarse el *bootstrap*, una técnica de remuestreo que genera nuevas muestras a partir de los datos originales mediante selección con reemplazo [9]. Cuando los datos presentan observaciones relacionadas entre sí, el remuestreo debe respetar esa estructura para no tratar como independientes observaciones que en realidad no lo son [16]. A partir de las muestras generadas pueden obtenerse distribuciones empíricas e intervalos de confianza que permiten valorar la incertidumbre asociada a la mejora observada.

Finalmente, la importancia por permutación permite analizar hasta qué punto un modelo depende de un predictor. El procedimiento consiste en alterar aleatoriamente los valores de una variable y observar cuánto empeora el rendimiento predictivo. Un aumento mayor del error indica que el modelo dependía en mayor medida de la información contenida en ese predictor. Esta medida debe interpretarse de forma condicional al modelo y al resto de variables disponibles, especialmente cuando existen predictores relacionados entre sí [10].

Capítulo 4

Diseño del estudio y construcción de la base de datos

4.1. Origen de los datos

La base de datos utilizada en este trabajo se construyó a partir de los archivos históricos de resultados y estadísticas del circuito ATP publicados en el repositorio público `tennis_atp`, mantenido por Jeff Sackmann [26]. En concreto, se utilizaron los archivos anuales de partidos individuales correspondientes a las temporadas definidas en el apartado siguiente. Estos registros contienen información sobre el torneo, los jugadores, el resultado y, cuando está disponible, las estadísticas asociadas a cada encuentro.

Los registros originales se encuentran estructurados a nivel de partido, de forma que cada observación representa un encuentro disputado entre dos jugadores. Entre la información disponible se incluyen variables relacionadas con la identidad de los participantes, su ranking, edad, altura, condición de cabeza de serie, tipo de entrada al torneo, superficie de juego, ronda, nivel de torneo y resultado final del encuentro.

Para la interpretación temporal debe tenerse en cuenta que la fecha disponible no corresponde al día exacto de cada partido. En la fuente original, la variable `tourney_date` representa generalmente el lunes situado al inicio o próximo al comienzo del torneo [26].

La amplitud temporal y la variedad de contextos competitivos de estos registros permiten analizar longitudinalmente el rendimiento de los jugadores. Sin embargo, su estructura original a nivel de partido no se ajusta directamente al objetivo del estudio, centrado en el rendimiento individual de cada tenista y en la reconstrucción de su historial competitivo previo. Por este motivo, fue necesario transformar y preparar los datos antes de realizar los análisis posteriores.

4.2. Periodo temporal de estudio

La fuente original utilizada en este trabajo contiene registros de partidos del circuito masculino desde 1968. Sin embargo, la cobertura no es homogénea durante todo el periodo: el propio repositorio indica que los rankings son mayoritariamente completos desde 1985 y que las estadísticas de partido están disponibles, en general, desde 1991 para los encuentros de nivel ATP [26].

Además, el circuito profesional ha experimentado cambios relevantes en su organización. Por este motivo, se estableció 2009 como primera temporada de la muestra analítica. Ese año el circuito fue reorganizado bajo la denominación ATP World Tour y se introdujeron las categorías Masters 1000, ATP 500 y ATP 250 [2]. Esta reorganización proporciona un punto de partida más homogéneo para comparar las temporadas consideradas en el estudio.

La construcción de las variables históricas requirió diferenciar entre las temporadas incluidas en el análisis y aquellas utilizadas exclusivamente como periodos auxiliares. En concreto, la temporada 2008 se conservó como año *buffer* (año auxiliar utilizado únicamente para aportar historial previo a la primera temporada analizada, sin formar parte de la muestra de estudio ni del modelado). Sus partidos contribuyen al cálculo del historial cuando se encuentran dentro de la ventana temporal correspondiente, pero no forman parte de la muestra analítica ni del posterior modelado.

Las alteraciones del calendario provocadas por la pandemia de COVID-19 rompieron la continuidad habitual de la competición. En marzo de 2020, la ATP suspendió durante

seis semanas el circuito profesional debido a los problemas de salud y seguridad derivados del brote de COVID-19 [1]. Por este motivo, 2020 se excluyó completamente del estudio. Como consecuencia de esta interrupción, 2021 tampoco se incorporó a la muestra analítica, ya que la reconstrucción de su historial previo, especialmente para la ventana principal de 365 días, quedaría afectada por la ausencia de 2020. No obstante, se conservó como año *buffer* para reconstruir la actividad competitiva previa de 2022 y evitar que sus variables de carga comenzaran artificialmente desde cero.

Por tanto, el conjunto operativo utilizado para reconstruir los historiales comprendió las temporadas 2008–2019 y 2021–2024. Los años 2008 y 2021 se emplearon exclusivamente como *buffer*, mientras que la muestra analítica quedó formada por 2009–2019 y 2022–2024.

Las temporadas 2009–2019 y 2022–2023 se destinaron al desarrollo del análisis y de los modelos. La temporada 2024 se reservó íntegramente como prueba temporal externa y no intervino en el análisis exploratorio, la selección de variables ni el ajuste de los modelos.

4.3. Transformación de la estructura de los partidos

Los registros originales del circuito ATP se encuentran organizados a nivel de partido, de manera que cada observación contiene simultáneamente la información correspondiente al ganador y al perdedor del encuentro.

Antes de realizar la transformación de la estructura, se revisaron los formatos presentes en la variable de marcador y se establecieron los criterios de inclusión y exclusión de los encuentros. El conjunto operativo inicial estaba formado por 47 317 partidos y 54 variables.

Se identificaron y eliminaron 295 encuentros no disputados, registrados mediante las expresiones W/O, WO o WALKOVER. Estos partidos no contienen actividad competitiva efectiva y, por tanto, no permiten calcular de forma coherente los juegos, los sets ni las variables de carga. Tras esta exclusión permanecieron 47 022 encuentros.

Los partidos no finalizados de forma ordinaria, identificados mediante etiquetas como RET, DEF, DEFAULT, ABD o ABANDONED, se conservaron cuando contenían actividad competitiva registrada. En estos casos, se contabilizaron los juegos efectivamente disputados,

mientras que el último parcial solo se consideró un set completo cuando cumplía las reglas de finalización correspondientes. El único encuentro interrumpido sin volumen competitivo observable se excluyó posteriormente durante las comprobaciones de calidad descritas en el Apartado 4.5.3.

Los *match tie-breaks* (desempates decisivos a puntos) registrados entre corchetes recibieron un tratamiento específico. Sus puntos no se sumaron como juegos ordinarios. Cuando el *match tie-break* había finalizado, se representó mediante un juego y un set a favor del ganador; cuando aparecía interrumpido, no se añadió dicha unidad. Esta convención permitió incorporar estos encuentros sin interpretar los puntos del desempate como juegos completos.

Para adaptar la base de datos al objetivo del estudio, cada partido se transformó en dos observaciones recíprocas, correspondientes respectivamente al ganador y al perdedor. De este modo, la unidad de análisis pasó a ser la participación de un jugador frente a un rival en un encuentro concreto, permitiendo disponer simultáneamente de información del jugador, del oponente y del contexto competitivo, así como reconstruir posteriormente el historial de cada tenista.

Cada encuentro conservó un identificador común, `_id_partido`, que permite vincular sus dos observaciones recíprocas. Dado que ambas filas proceden del mismo partido y comparten el contexto competitivo, no deben considerarse observaciones independientes al definir las futuras particiones de los datos. En consecuencia, las dos perspectivas de un mismo encuentro deberán asignarse siempre al mismo subconjunto de desarrollo, validación o prueba.

4.4. Definición de la variable objetivo

Una de las primeras decisiones metodológicas del trabajo consistió en establecer cómo medir el rendimiento de un jugador en un partido de tenis. Aunque el resultado final del encuentro constituye el indicador más evidente del desempeño competitivo, su carácter binario limita la información que aporta sobre el desarrollo del partido.

Con el objetivo de disponer de una medida más detallada del rendimiento, se seleccionó como variable objetivo el porcentaje de juegos ganados por el jugador en cada encuentro. Esta métrica permite cuantificar su desempeño durante el partido y diferenciar situaciones competitivas que quedarían representadas de forma idéntica mediante una clasificación binaria entre victoria y derrota.

Matemáticamente, el porcentaje de juegos ganados por el jugador i en el partido m se definió como:

$$p_{i,m} = \frac{J_{i,m}}{J_{i,m} + J_{r(i,m),m}}, \quad 0 \leq p_{i,m} \leq 1,$$

donde $J_{i,m}$ representa el número de juegos ganados por el jugador analizado y $J_{r(i,m),m}$ el número de juegos ganados por su rival en el mismo encuentro. En la base de datos, esta variable se almacenó con el nombre `porcentaje_juegos_ganados` y se expresó en una escala comprendida entre 0 y 1.

4.5. Construcción y preparación de los predictores tradicionales

Tras transformar la base de datos al formato jugador-partido y generar las variables derivadas necesarias durante este proceso, se obtuvo inicialmente un conjunto operativo formado por 94 044 observaciones y 61 variables. Este conjunto incluía los años *buffer* empleados para reconstruir los historiales y la temporada reservada para la prueba temporal externa, ya que las primeras tareas de limpieza, clasificación funcional y codificación debían aplicarse de forma homogénea a todos los registros.

A partir de esta estructura se identificaron y prepararon las variables que podían utilizarse como predictores tradicionales por estar disponibles antes del comienzo del encuentro. La evaluación y selección posterior de estos predictores se realizó exclusivamente sobre el conjunto de desarrollo, excluyendo los años *buffer* y la temporada 2024 reservada para la prueba temporal externa.

4.5.1. Clasificación funcional de las variables

En primer lugar, las 61 variables disponibles se clasificaron según la función que desempeñaban dentro del estudio. Se establecieron cuatro grupos:

- **Variables contextuales:** identificadores, nombres, fechas y otros campos utilizados para organizar los registros y mantener la trazabilidad de los partidos.
- **Variables potencialmente predictivas:** información conocida antes del comienzo del encuentro y, por tanto, susceptible de ser utilizada para explicar o predecir el rendimiento.
- **Variables generadas durante el partido:** estadísticas como los aces, dobles faltas, puntos de servicio, puntos de rotura, juegos o duración del encuentro.
- **Variable de rendimiento:** porcentaje de juegos ganados como variable objetivo.

Esta clasificación permitió distinguir la información disponible antes del partido de aquella generada durante el encuentro. Las variables producidas durante el partido no se incorporaron al modelo base, aunque las medidas de juegos y sets se conservaron para construir posteriormente las variables de carga competitiva.

Como resultado de esta primera clasificación se identificaron 16 variables contextuales, 19 variables potencialmente predictivas, 25 variables correspondientes al desarrollo del partido y la variable de rendimiento.

4.5.2. Conjunto inicial de variables predictivas

Las 19 variables candidatas se seleccionaron por estar disponibles antes del inicio del encuentro. Estas variables recogían tres dimensiones principales:

- **Contexto competitivo:** superficie, nivel del torneo, ronda, tamaño del cuadro y número máximo de sets.
- **Características del jugador:** ranking, puntos de ranking, edad, altura, mano dominante, condición de cabeza de serie y tipo de entrada al torneo.

- **Características del rival:** las mismas variables anteriores referidas al oponente.

Posteriormente, estas variables se dividieron en función de su naturaleza. Se identificaron 12 variables numéricas y 7 variables categóricas. Esta separación fue necesaria debido a que las variables categóricas requerían una revisión y codificación previa antes de poder incorporarse a los análisis estadísticos.

4.5.3. Tratamiento de las variables categóricas

Antes de realizar la codificación, se analizaron las frecuencias, los valores ausentes y las categorías presentes en cada variable. Esta revisión permitió detectar etiquetas inconsistentes, categorías escasamente representadas y valores que requerían un tratamiento específico.

En las variables `mano_dominante` y `mano_dominante_rival`, los valores desconocidos o no estandarizados se agruparon en la categoría `UNKNOWN`. En `tipo_entrada` y `tipo_entrada_rival`, se normalizaron las etiquetas, los valores ausentes se interpretaron como entrada directa mediante la categoría `DIRECT` y determinadas categorías extremadamente minoritarias se agruparon inicialmente como `OTROS`.

Las variables `cabeza_serie` y `cabeza_serie_rival` contenían originalmente el número de cabeza de serie asignado a cada participante, mientras que los valores ausentes indicaban que el jugador no presentaba esta condición. Para representar esta información de forma homogénea, ambas variables se transformaron en indicadores binarios, asignando el valor 1 a los jugadores que eran cabeza de serie y el valor 0 al resto.

Las abreviaturas de `nivel_torneo` se sustituyeron por denominaciones interpretables, diferenciando entre Grand Slam, Masters 1000, ATP, Copa Davis, ATP Finals y Juegos Olímpicos. Los valores ausentes de `superficie` se mantuvieron temporalmente mediante la categoría `UNKNOWN`.

La variable `ronda` recibió un tratamiento específico. Las rondas eliminatorias se codificaron ordinalmente desde la primera ronda hasta la final, mediante valores crecientes entre 1 y 7. Los encuentros disputados mediante el sistema *round robin* (sistema de competición

de todos contra todos) se identificaron mediante la variable binaria `es_round_robin`. En estos casos, `ronda_encoded` tomó el valor 0 y `es_round_robin` el valor 1, por lo que dicho cero no representa información desconocida, sino un formato de competición diferente al sistema eliminatorio.

El resto de las variables categóricas se transformó mediante codificación *one-hot*, generando indicadores binarios para las categorías de superficie y nivel del torneo, compartidas por ambos jugadores del encuentro, y para la mano dominante y el tipo de entrada tanto del jugador como de su rival.

Durante la depuración se eliminaron 12 observaciones correspondientes a seis encuentros por el tercer puesto, identificados mediante la categoría de ronda `BR`, ya que estos partidos no determinan la progresión de los jugadores hacia el título y presentan una naturaleza competitiva distinta a la del cuadro eliminatorio habitual y, además, muestran una calidad de datos muy escasa. Posteriormente, durante las comprobaciones de calidad, se detectó un único partido sin volumen competitivo observable, con cero juegos y cero sets registrados. Este encuentro se eliminó conjuntamente con sus dos observaciones recíprocas.

Como resultado, el conjunto operativo utilizado para construir las variables de carga quedó formado por 94 030 observaciones jugador-partido, correspondientes a 47 015 encuentros. Este conjunto incluía los años *buffer* necesarios para reconstruir los historiales competitivos. Una vez excluidos dichos años auxiliares, la muestra de estudio quedó formada por 82 402 observaciones jugador-partido, correspondientes a 41 201 encuentros.

Tras la codificación de las variables categóricas, las 19 variables predictivas iniciales quedaron representadas mediante 47 predictores numéricos candidatos. Su evaluación y selección posterior se desarrollan en el Capítulo 5.

4.6. Construcción de las variables de carga competitiva acumulada

4.6.1. Definición operacional y alcance de la carga competitiva observable

La carga competitiva acumulada se define operacionalmente como la exposición competitiva previa de un jugador que puede reconstruirse a partir de los registros históricos disponibles antes de una nueva participación. Esta exposición se representa mediante el volumen, la frecuencia, la recencia y la distribución temporal de la actividad competitiva anterior.

El volumen competitivo se aproximó inicialmente mediante el número de juegos, sets y partidos disputados, considerando posteriormente su posible redundancia. Los juegos permiten representar con mayor detalle la exposición competitiva y han sido utilizados previamente como aproximación de la carga de competición en tenis profesional [20]. De forma complementaria, el número de torneos permitió representar la frecuencia de participación, mientras que la separación entre inicios competitivos y el número de semanas con competición recogieron, respectivamente, la proximidad y la distribución temporal de la actividad previa.

Estas variables no constituyen medidas directas de fatiga fisiológica ni de carga interna. La base de datos utilizada no contiene información completa sobre entrenamientos, desplazamientos, lesiones, percepción subjetiva del esfuerzo, recuperación individual o condiciones ambientales. En consecuencia, las medidas construidas deben interpretarse como indicadores de carga competitiva externa observable y no como una cuantificación directa del estado fisiológico del jugador [4].

La literatura ha relacionado la competición en tenis con alteraciones fisiológicas, neuromusculares y perceptivas [24] y ha estudiado la carga competitiva acumulada mediante el volumen de juegos disputados [20]. Estas evidencias justifican considerar el historial

competitivo, pero no permiten interpretar las variables construidas como medidas directas de fatiga ni asumir efectos causales sobre el rendimiento. Su objetivo es evaluar si la exposición competitiva observable aporta información estadística y predictiva adicional respecto a los predictores tradicionales.

Las definiciones siguientes se aplican de forma independiente dentro del bloque temporal operativo correspondiente. Por tanto, una participación solo puede formar parte del historial de otra observación cuando ambas pertenecen al mismo bloque temporal, evitando conectar artificialmente periodos separados por la interrupción del calendario analizado.

Sea $T_{i,t}$ la fecha de inicio de la participación t del jugador i . El conjunto de participaciones históricas disponibles antes de dicha fecha se define como:

$$\mathcal{H}_{i,t} = \{k : T_{i,k} < T_{i,t}\}.$$

Para una ventana temporal de amplitud w , el historial reciente queda definido por:

$$\mathcal{H}_{i,t}^{(w)} = \{k : T_{i,t} - w \leq T_{i,k} < T_{i,t}\}.$$

A partir de este conjunto, la carga acumulada correspondiente a una medida competitiva z puede expresarse como:

$$C_{i,t}^{(w,z)} = \sum_{k \in \mathcal{H}_{i,t}^{(w)}} z_{i,k},$$

donde $z_{i,k}$ representa la cantidad de juegos, sets, partidos o torneos asociada a una participación anterior del jugador.

La desigualdad estricta $T_{i,k} < T_{i,t}$ garantiza que el torneo actual quede excluido de sus propias variables de carga. De este modo, todas las medidas predictoras se construyen únicamente con información que estaba disponible antes de la participación cuyo rendimiento se pretende analizar.

4.6.2. Unidad temporal y transformación a los niveles jugador–torneo y jugador–fecha

La base de datos empleada en la modelización utiliza como unidad de observación la participación de un jugador en un partido. Esta estructura resulta adecuada para analizar el rendimiento individual, pero no puede utilizarse directamente para construir el historial competitivo sin realizar una transformación previa. Un jugador que avanza varias rondas en un mismo torneo aparece repetido en tantas filas como partidos disputa, aunque todas ellas comparten la misma fecha de torneo.

La fuente de datos no proporciona la fecha exacta de cada partido, sino una única fecha asociada al torneo [26]. Aunque la variable `ronda` permite aproximar el orden de algunos encuentros, no permite conocer con precisión cuándo se disputaron ni los días reales de recuperación. Por este motivo, y para mantener un criterio uniforme, los registros se agregaron a nivel jugador–torneo.

Sea $\mathcal{M}_{i,u}$ el conjunto de partidos disputados por el jugador i en el torneo u . Para una medida competitiva z , la actividad total generada durante dicha participación se definió como:

$$z_{i,u} = \sum_{m \in \mathcal{M}_{i,u}} z_{i,m},$$

donde $z_{i,m}$ representa la cantidad correspondiente al partido m . Esta operación se aplicó a las medidas de juegos, sets y partidos disputados, conservando además la información contextual necesaria para identificar la participación.

De este modo, un jugador que disputaba varios encuentros dentro de un mismo torneo generaba una única observación en la estructura temporal intermedia. Al aplicar esta transformación sobre las 94 030 observaciones jugador–partido del conjunto operativo, se obtuvieron 50 051 observaciones jugador–torneo.

Se detectó un único caso en el que un mismo jugador aparecía en dos torneos diferentes con la misma fecha de inicio. Como la información disponible no permitía determinar cuál

de las dos participaciones había ocurrido primero, no resultaba metodológicamente válido imponer un orden artificial entre ellas. En caso contrario, la actividad de uno de los torneos podría incorporarse incorrectamente al historial previo del otro.

Por este motivo, las participaciones que coincidían para un mismo jugador y fecha se agregaron en una única unidad jugador–fecha. Sea $U_{i,d}$ el conjunto de torneos registrados para el jugador i en la fecha d . Para una medida competitiva z , la actividad total correspondiente a dicha fecha se definió como:

$$z_{i,d} = \sum_{u \in U_{i,d}} z_{i,u},$$

donde $z_{i,u}$ representa la cantidad de juegos, sets o partidos disputados por el jugador i en el torneo u . El número de torneos se obtuvo sumando una unidad por cada participación registrada en esa fecha.

La consolidación produjo una estructura formada por 50 050 observaciones jugador–fecha. Esta fue la unidad utilizada para construir las variables históricas y las cargas competitivas acumuladas. Después, las variables resultantes se incorporaron nuevamente al conjunto operativo jugador–partido sin modificar su número de observaciones.

Como consecuencia de este procedimiento, todos los partidos disputados por un jugador dentro de un mismo torneo reciben la misma carga previa, correspondiente a la exposición competitiva observable anterior a su fecha de inicio. La carga no se actualiza entre rondas, ya que la fuente de datos no proporciona la fecha individual de cada partido.

4.6.3. Construcción del historial competitivo previo y separación de bloques temporales

Una vez obtenida la estructura jugador–fecha, el siguiente paso consistió en ordenar cronológicamente las participaciones de cada jugador para identificar la información disponible antes de cada torneo. Esta ordenación constituye un requisito fundamental para construir variables históricas, ya que cualquier error en la secuencia temporal podría

provocar que información contemporánea o futura se incorporase incorrectamente a los predictores.

El conjunto operativo no presenta una cobertura temporal continua, sino que se divide en dos intervalos separados por la exclusión completa de los registros correspondientes a 2020. Además, como se explicó en el Apartado 4.2, las temporadas 2008 y 2021 se conservaron como años *buffer* para reconstruir el historial previo de 2009 y 2022, respectivamente.

Por este motivo, se definieron dos bloques temporales operativos independientes:

$$B_1 = \{2008, \dots, 2019\},$$

$$B_2 = \{2021, \dots, 2024\}.$$

La separación de ambos bloques impide que la última participación registrada en 2019 sea considerada como antecedente de una observación perteneciente al segundo intervalo. En cambio, las participaciones de 2021 sí pueden contribuir al historial de 2022, aunque no formen parte de la muestra analítica ni del posterior modelado.

Los historiales se reconstruyeron de forma independiente para cada combinación jugador–bloque temporal. Las observaciones se ordenaron utilizando el identificador del jugador, el bloque temporal y la fecha de inicio de la participación. Para un jugador i dentro del bloque b , la secuencia cronológica se expresa como:

$$T_{i,1}^{(b)} < T_{i,2}^{(b)} < \dots < T_{i,n_i}^{(b)},$$

donde $T_{i,t}^{(b)}$ representa la fecha de la participación t del jugador i dentro del bloque temporal b .

Una vez ordenada la secuencia, la información correspondiente a la participación inmediatamente anterior se trasladó a la observación actual. Para una medida competitiva z , esta operación se define como:

$$L_{i,t}^{(z)} = z_{i,t-1}, \quad t > 1,$$

donde $z_{i,t-1}$ representa el valor observado en la participación anterior y $L_{i,t}^{(z)}$ representa la información histórica asignada al torneo actual. Computacionalmente, esta operación se implementó mediante un desplazamiento de una posición dentro de cada historial jugador–bloque.

A partir de este procedimiento se recuperaron la fecha, los juegos, los sets, los partidos y el número de torneos asociados a la participación inmediatamente anterior. También se calculó la separación calendárica entre los inicios de dos participaciones consecutivas:

$$D_{i,t} = T_{i,t}^{(b)} - T_{i,t-1}^{(b)}.$$

Esta diferencia se expresó en días. No obstante, debe interpretarse como la separación entre las fechas de inicio de dos participaciones competitivas y no como una medida exacta de los días de descanso, puesto que la fuente de datos no contiene la fecha específica del último partido disputado dentro del torneo anterior.

La primera observación de cada historial jugador–bloque no dispone de una participación anterior observable. En estos casos:

$$L_{i,1}^{(z)} = \text{NA},$$

donde NA indica un valor ausente.

En total se identificaron 2 198 historiales independientes jugador–bloque y, por tanto, 2 198 primeras observaciones sin una participación anterior observable dentro del bloque correspondiente. Esta cifra no representa el número de jugadores distintos, ya que un mismo tenista puede generar un historial independiente en cada uno de los dos bloques temporales.

4.6.4. Construcción de las ventanas temporales de carga

Con el objetivo de representar la exposición competitiva previa a distintas escalas temporales, se construyeron tres familias de variables: una ventana móvil de 365 días, la carga acumulada durante la temporada y una ventana móvil de 180 días. Para cada una se calcularon inicialmente los juegos, sets, partidos y torneos disputados.

La literatura ha señalado que, además del volumen acumulado, su distribución a lo largo del tiempo puede resultar relevante [20]. Las tres definiciones se establecieron como decisiones operativas para representar horizontes temporales complementarios, utilizando la ventana de 365 días como medida principal y la de 180 días como análisis alternativo de robustez.

Ventana móvil de 365 días

La primera definición recoge toda la actividad competitiva registrada durante los 365 días anteriores a la fecha actual. Para una medida z , la carga anual se define como:

$$C_{i,t}^{(365,z)} = \sum_k z_{i,k} \mathbb{I}(T_{i,t} - 365 \leq T_{i,k} < T_{i,t}),$$

donde $\mathbb{I}(\cdot)$ representa la función indicadora. A partir de esta expresión se construyeron las variables `juegos_365d`, `sets_365d`, `partidos_365d` y `torneos_365d`.

La ventana de 365 días se utilizó como definición principal por ofrecer un horizonte anual fijo, incluso cuando abarca participaciones de dos temporadas diferentes. Cuando no existía actividad previa dentro de la ventana, la carga se asignó a cero. Para distinguir una ausencia real de actividad de una cobertura temporal insuficiente al comienzo de cada bloque, se creó el indicador `historial_365d_completo`. De las 43 863 observaciones jugador–fecha de la muestra de estudio, 43 770 presentaron una ventana completa de 365 días y 93 una cobertura incompleta.

Carga acumulada durante la temporada

La carga estacional acumula únicamente la actividad anterior correspondiente a la misma temporada competitiva:

$$\mathcal{H}_{i,t}^{(\text{temp})} = \{k : s_{i,k} = s_{i,t}, \quad T_{i,k} < T_{i,t}\}, \quad C_{i,t}^{(\text{temp},z)} = \sum_{k \in \mathcal{H}_{i,t}^{(\text{temp})}} z_{i,k}.$$

A partir de esta definición se obtuvieron las distintas variables utilizadas para representar la carga competitiva acumulada durante la temporada: `juegos_temporada`, `sets_temporada`, `partidos_temporada` y `torneos_temporada`. La acumulación se reinició al comienzo de cada `match_year`, por lo que la primera participación de cada jugador presentó carga cero. Dado que la oportunidad de acumular actividad aumenta conforme avanza la temporada, se incorporó como control `dias_desde_inicio_temporada`, calculada desde la primera fecha observable de cada temporada.

Ventana móvil de 180 días

Como especificación de robustez, se calculó la actividad competitiva acumulada durante los 180 días anteriores:

$$\mathcal{H}_{i,t}^{(180)} = \{k : T_{i,t} - 180 \leq T_{i,k} < T_{i,t}\}, \quad C_{i,t}^{(180,z)} = \sum_{k \in \mathcal{H}_{i,t}^{(180)}} z_{i,k}.$$

Se obtuvieron las variables `juegos_180d`, `sets_180d`, `partidos_180d` y `torneos_180d`. También se creó el indicador `historial_180d_completo`. La ventana representa una escala de medio plazo y permite comprobar si los resultados se mantienen al utilizar un horizonte más corto que el anual.

Los años *buffer* proporcionaron una cobertura suficiente para reconstruir los 180 días anteriores de todas las observaciones incluidas en la muestra de estudio. En consecuencia, las 43 863 observaciones jugador–fecha de dicha muestra presentaron una cobertura temporal completa para esta ventana.

Dado que la ventana de 180 días está contenida en la de 365 días, se verificó que

$$\mathcal{H}_{i,t}^{(180)} \subseteq \mathcal{H}_{i,t}^{(365)} \quad \text{y} \quad C_{i,t}^{(180,z)} \leq C_{i,t}^{(365,z)}$$

para todas las medidas competitivas no negativas. También se comprobó que toda observación con cobertura completa de 365 días dispusiera de cobertura completa para la ventana de 180 días.

4.6.5. Variables de la participación anterior, separación temporal y densidad competitiva reciente

Las ventanas de 180 y 365 días y la carga acumulada durante la temporada permiten representar el volumen competitivo previo en diferentes horizontes temporales. Sin embargo, estas medidas no describen completamente la proximidad de la última participación ni la forma en que la actividad se distribuye durante el periodo reciente. Por este motivo, se construyeron variables adicionales destinadas a representar la carga inmediata, la separación temporal entre participaciones y la densidad reciente del calendario.

La incorporación de estas dimensiones responde al carácter dinámico de la exposición competitiva. En la literatura sobre monitorización de cargas destaca la importancia de seguir la exposición del deportista de forma longitudinal y de interpretar el trabajo externo junto con la respuesta interna que este genera [4]. En el contexto del tenis, se ha señalado que las respuestas fisiológicas, neuromusculares y perceptivas asociadas a la competición pueden prolongarse y agravarse cuando se disputan encuentros en días consecutivos [24]. En tenis profesional, Kovalchik emplea los juegos disputados como medida observable de carga competitiva y analiza su acumulación a lo largo de las semanas de competición [20].

Carga de la participación inmediatamente anterior

La actividad correspondiente a la participación inmediatamente anterior del jugador se definió como

$$L_{i,t}^{(z)} = z_{i,t-1}, \quad t > 1,$$

donde z representa los juegos, sets, partidos o torneos disputados. Los juegos se consideraron la medida principal por ofrecer una representación más detallada del volumen competitivo, mientras que las demás medidas se conservaron inicialmente para evaluar su redundancia. Cuando no existía una participación anterior observable, el valor se mantuvo como ausente.

Separación entre inicios competitivos

La separación entre la participación actual y la inmediatamente anterior se calculó, en días, mediante

$$D_{i,t} = T_{i,t} - T_{i,t-1}.$$

Esta variable representa la separación calendárica entre los inicios de ambas participaciones, pero no los días exactos de descanso, ya que no se dispone de las fechas individuales de los partidos.

Un análisis exploratorio mostró que `dias_entre_inicios_competitivos` presentaba una distribución fuertemente asimétrica, con numerosos intervalos cortos y algunos valores excepcionalmente elevados. Para comprimir especialmente los intervalos de mayor magnitud y reducir la asimetría se aplicó la transformación logarítmica natural

$$D_{i,t}^{(\log)} = \log(1 + D_{i,t}).$$

La transformación mantiene el orden de las observaciones y reduce el peso relativo de los intervalos más elevados sin eliminar registros. La variable original se conservó para facilitar la interpretación en días, mientras que $\log(1 + D_{i,t})$ se utilizó como predictor candidato en los análisis posteriores. La comparación de ambas distribuciones se recoge en la Figura A.1 del Anexo A.2.

Densidad competitiva durante los 56 días anteriores

El volumen acumulado no permite distinguir si la actividad previa se concentró en un número reducido de semanas o se distribuyó de manera continuada. Para representar esta dimensión se construyó la variable `semanas_con_competicion_56d`.

Sea $w(T_{i,k})$ la semana natural, comprendida entre lunes y domingo, que contiene la fecha competitiva $T_{i,k}$. El número de semanas distintas con actividad previa se define como:

$$S_{i,t}^{(56)} = |\{w(T_{i,k}) : T_{i,t} - 56 \leq T_{i,k} < T_{i,t}\}|.$$

La variable `semanas_con_competicion_56d` cuenta las semanas naturales distintas con al menos un inicio competitivo durante los 56 días anteriores, excluyendo la participación actual. Esta ventana fija de ocho semanas se estableció como una definición operativa de la densidad competitiva reciente y no como un umbral fisiológico de fatiga o recuperación.

Asimismo, se creó el indicador `historial_56d_completo` para identificar las observaciones con cobertura íntegra de la ventana. Gracias a los años *buffer*, las 43 863 observaciones jugador–fecha de la muestra de estudio presentaron cobertura completa.

En conjunto, las variables construidas representan tres dimensiones complementarias de la exposición competitiva previa: el volumen de la participación anterior, la separación calendárica y la densidad competitiva reciente.

El procedimiento general utilizado para construir las variables de carga competitiva se resume en la Figura 4.1.




Figura 4.1: Esquema de construcción de las variables de carga competitiva.

4.6.6. Validación temporal y comprobación de las variables construidas

Una vez construidas las variables de carga competitiva, se aplicó un protocolo de validación destinado a comprobar su coherencia estructural y temporal y a descartar la incorporación de información contemporánea o futura.

En primer lugar, se verificó que la reincorporación de las cargas no modificara el número de observaciones ni de partidos y que cada encuentro conservara sus dos perspectivas jugador-partido. Asimismo, las estructuras jugador-torneo y jugador-fecha mantuvieron claves únicas.

La reconstrucción del historial previo se comprobó dentro de cada combinación jugador–bloque temporal, verificando el orden cronológico de las participaciones, la correspondencia exacta con la observación anterior y que las fechas históricas fueran estrictamente anteriores a la participación actual. También se verificó que `dias_entre_inicios_competitivos` reprodujera exactamente la diferencia entre ambas fechas.

En las cargas acumuladas de 365 días, 180 días y temporada se comprobó la ausencia de valores negativos y se verificó, para todas las medidas competitivas no negativas, que

$$C_{i,t}^{(180,z)} \leq C_{i,t}^{(365,z)}.$$

Los indicadores de cobertura temporal se validaron por separado para distinguir una ausencia real de actividad previa de una cobertura incompleta.

Finalmente, se comprobó que todos los partidos disputados por un jugador dentro de un mismo torneo recibieran la misma carga previa y que, en las dos perspectivas de cada encuentro, las variables del jugador y del rival procedieran exclusivamente de sus respectivos historiales anteriores. De este modo, la construcción excluyó la actividad generada durante el propio torneo.

Estas comprobaciones respaldan la coherencia temporal de las variables construidas y reducen el riesgo de fuga de información. La separación temporal de entrenamiento, validación y prueba se aborda posteriormente durante la fase de modelización.

Capítulo 5

Análisis exploratorio y selección de variables

Una vez construidas y preparadas las variables candidatas, se realizó un análisis exploratorio destinado a estudiar su distribución, su relación con el rendimiento y la posible existencia de información redundante. El análisis se aplicó a dos familias de predictores: las variables tradicionales disponibles antes del partido y las variables de carga competitiva derivadas del historial previo de los jugadores.

Ambos bloques se examinaron mediante medidas de asociación y análisis de dependencia entre predictores. La información mutua se utilizó con finalidades diferentes: para estudiar la relación de los predictores tradicionales con el rendimiento y para detectar dependencias no lineales entre las variables de carga. En estas últimas también se consideraron su cobertura temporal, asimetría, estabilidad y relación con el momento de la temporada.

La selección no se basó en una única medida estadística ni en la eliminación automática de variables con asociaciones simples reducidas. Se combinaron la disponibilidad de la información, la asociación con el rendimiento, la redundancia entre predictores, la interpretabilidad deportiva y la coherencia con los objetivos del estudio. A partir de estos

criterios se definieron los predictores del modelo base y las variables de carga incorporadas a los modelos ampliados.

Salvo indicación contraria, los análisis de asociación y dependencia se realizaron a nivel jugador-partido, la misma unidad utilizada en la modelización. Algunas comprobaciones centradas en la estructura temporal de las cargas se realizaron a nivel jugador-torneo para evitar repetir una misma carga en todos los partidos de una participación.

5.1. Distribución, valores ausentes y calidad de los datos

Antes de estudiar la relación de los predictores con el rendimiento, se revisaron sus distribuciones, valores ausentes, valores extremos y frecuencias, con el objetivo de detectar posibles problemas de calidad y características que debieran considerarse durante la selección de variables.

5.1.1. Predictores tradicionales

El análisis se realizó sobre los 47 predictores candidatos obtenidos tras la preparación descrita en el capítulo anterior. Una vez interpretados los valores ausentes de las variables de cabeza de serie como ausencia de dicha condición y transformadas estas en indicadores binarios, los valores ausentes restantes se concentraron principalmente en la altura, el ranking y los puntos de ranking y, en mucha menor medida, en la edad. Asimismo, algunos indicadores derivados de variables categóricas presentaron una frecuencia muy reducida.

Estos resultados se tuvieron en cuenta posteriormente junto con la asociación con el rendimiento, la dependencia entre predictores y la información mutua, sin aplicar una eliminación automática basada únicamente en la frecuencia o en la presencia de valores ausentes.

5.1.2. Variables de carga competitiva

Las cargas acumuladas presentaron, en general, distribuciones asimétricas hacia la derecha, con una mayor concentración de observaciones en valores bajos o intermedios. Los

valores elevados se revisaron para comprobar su coherencia con la actividad competitiva registrada y no se eliminaron automáticamente, ya que podían representar periodos reales de elevada participación.

La mayor asimetría se observó en la separación entre inicios competitivos consecutivos, circunstancia que justificó la utilización de su transformación logarítmica como predictor candidato, manteniendo también la variable original para conservar su interpretación en días.

5.2. Asociación con la variable de rendimiento

Una vez examinadas la calidad y la distribución de las variables, se estudió su asociación con la variable objetivo, el porcentaje de juegos ganados. Para ello se utilizaron los coeficientes de correlación de Pearson, Spearman y Kendall τ_b , cuyos fundamentos y diferencias se desarrollan en el capítulo de fundamentos teóricos.

El coeficiente de Pearson permitió examinar relaciones lineales, mientras que Spearman y Kendall se emplearon para estudiar asociaciones monótonas basadas en el orden de las observaciones. La comparación conjunta de los tres coeficientes permitió valorar si los patrones observados se mantenían al utilizar medidas con propiedades diferentes.

Estos resultados se interpretaron de forma descriptiva y no se utilizaron como criterios automáticos de selección. Una asociación reducida no implicó por sí sola la eliminación de una variable, ya que esta podía aportar información mediante relaciones no lineales, interacciones con otros predictores o efectos condicionados por el contexto competitivo.

5.2.1. Predictores tradicionales

Los tres coeficientes mostraron resultados consistentes en las variables relacionadas con el nivel competitivo de los jugadores. El ranking, los puntos de ranking y sus correspondientes variables para el rival presentaron las asociaciones más relevantes con la variable objetivo.

También se observaron asociaciones en la condición de cabeza de serie y en determinadas modalidades de entrada al torneo. Estas variables se conservaron inicialmente para valorar su posible aportación junto con el resto de predictores.

Por el contrario, variables como la edad, la mano dominante y algunas categorías poco frecuentes mostraron asociaciones simples reducidas. No obstante, estas variables no se eliminaron únicamente por presentar coeficientes bajos, ya que podían mantener relaciones no lineales, intervenir mediante interacciones con otros predictores o aportar información en contextos competitivos específicos.

Las variables compartidas por los dos jugadores de un mismo encuentro, como la superficie, la ronda, el nivel del torneo o el número máximo de sets, presentaron asociaciones marginales próximas a cero en algunos de los análisis.

Este comportamiento debe interpretarse teniendo en cuenta la estructura jugador-partido. Cada encuentro genera dos observaciones recíprocas con el mismo contexto competitivo y resultados complementarios, por lo que una asociación marginal reducida no implica que estas variables carezcan de utilidad en un modelo multivariante.

5.2.2. Variables de carga competitiva

El análisis de asociación entre la carga competitiva y el porcentaje de juegos ganados se realizó sobre las observaciones con cobertura temporal completa, participación anterior observable y valores disponibles en las variables consideradas. Se utilizaron los coeficientes de Pearson, Spearman y Kendall τ_b . En términos generales, las variables de carga absoluta presentaron relaciones de magnitud reducida o moderada con el rendimiento. La asociación monótona más destacada correspondió a los juegos acumulados durante los 365 días anteriores:

$$\rho_s(\text{juegos_365d}, \text{porcentaje_juegos_ganados}) = 0,2150.$$

También se observaron asociaciones positivas de menor intensidad para otras medidas de carga. En conjunto, una mayor exposición competitiva observable tendió a coincidir

con un mayor porcentaje de juegos ganados, aunque estas relaciones fueron limitadas y pueden estar condicionadas por el nivel competitivo y la capacidad para avanzar rondas.

La separación entre inicios competitivos consecutivos presentó una asociación negativa de pequeña magnitud. Por tanto, los intervalos más prolongados sin una participación registrada tendieron a coincidir con un porcentaje de juegos ganados ligeramente inferior en el torneo posterior. Este resultado debe interpretarse de forma descriptiva, ya que la separación entre competiciones puede estar relacionada con otros factores no observados, como lesiones, decisiones de calendario, nivel competitivo o periodos de inactividad.

El análisis por niveles de carga mostró además algunos patrones no lineales. Mientras que las variables basadas en el volumen de juegos presentaron, en general, una tendencia creciente, el número de torneos, la separación entre participaciones y la densidad competitiva reciente mostraron comportamientos menos regulares. En particular, los niveles intermedios de `semanas_con_competicion_56d` alcanzaron un porcentaje medio de juegos ganados superior al observado en los niveles de máxima densidad, sin que ello permita identificar un nivel óptimo de actividad ni realizar una interpretación fisiológica.

Posteriormente, el análisis se amplió incorporando la carga previa del rival. Para cada medida de carga X , se construyó una variable diferencial definida como:

$$\Delta X_{i,m} = X_{i,m} - X_{r(i,m),m}.$$

En esta expresión, $X_{i,m}$ representa la carga previa del jugador analizado y $X_{r(i,m),m}$ la carga correspondiente a su rival en el mismo encuentro. Los valores positivos indican que el jugador presentaba una carga superior a la de su oponente, mientras que los valores negativos representan la situación contraria.

Para comparar las cargas absolutas con sus correspondientes diferencias jugador–rival se utilizó una muestra emparejada, de modo que ambas medidas se evaluarán sobre exactamente los mismos partidos. En esta comparación, las variables diferenciales mostraron asociaciones más intensas con el porcentaje de juegos ganados que sus correspondientes

cargas absolutas. La relación más destacada correspondió a la diferencia de juegos acumulados durante los 365 días anteriores:

$$\rho_s(\text{diff_juegos_365d}, \text{porcentaje_juegos_ganados}) = 0,3589.$$

La comparación se muestra en la Figura 5.1.




Figura 5.1: Correlaciones de Spearman de las cargas absolutas y de las diferencias jugador-rival con el porcentaje de juegos ganados.

También presentaron asociaciones relevantes las diferencias en los juegos acumulados durante la temporada y en los juegos disputados en la participación inmediatamente anterior. Por el contrario, cuando el jugador llevaba relativamente más tiempo sin competir que su rival, el porcentaje de juegos ganados tendía a ser inferior.

El aumento de las asociaciones al utilizar diferencias jugador-rival resulta coherente con la naturaleza comparativa del tenis. Estas variables incorporan simultáneamente la carga previa del jugador y la de su rival, por lo que representan de forma directa la diferencia de exposición competitiva entre ambos.

No obstante, estas asociaciones no demuestran que una mayor carga competitiva produzca directamente un mejor rendimiento. Un volumen elevado de competición puede reflejar simultáneamente un mayor nivel deportivo, una presencia más continuada en el circuito o una mayor capacidad para avanzar rondas. Por este motivo, la aportación específica de las variables de carga deberá evaluarse posteriormente mediante modelos multivariantes que incorporen también los predictores tradicionales.

5.3. Dependencia y redundancia entre predictores

Además de estudiar la relación de cada variable con el rendimiento, se analizaron las dependencias existentes entre los propios predictores. El objetivo fue identificar variables que representaran dimensiones prácticamente equivalentes y cuya incorporación simultánea pudiera introducir información redundante.

Las correlaciones entre predictores se utilizaron como un procedimiento exploratorio de detección. Se revisaron especialmente las relaciones de mayor intensidad, aunque no se aplicó un umbral automático de eliminación. La decisión final consideró también la interpretación de las variables, su posible aportación complementaria y su función dentro del modelo.

5.3.1. Predictores tradicionales

La relación más elevada se observó entre el ranking y los puntos de ranking. La correlación de Spearman alcanzó aproximadamente:

$$\rho_s \approx -0,99.$$

Este resultado muestra que ambas variables representan prácticamente la misma dimensión competitiva mediante escalas inversas: una posición de ranking numéricamente reducida suele corresponder a una cantidad elevada de puntos ATP.

También se observaron asociaciones elevadas entre determinadas variables binarias generadas mediante codificación *one-hot*. Este comportamiento apareció especialmente en las categorías de superficie, mano dominante y tipo de entrada al torneo.

Estas asociaciones se encuentran parcialmente determinadas por el carácter mutuamente excluyente de las categorías. Por ejemplo, una observación clasificada en una superficie determinada no puede pertenecer simultáneamente a otra. Por tanto, estas relaciones no se interpretaron de la misma forma que la redundancia observada entre dos medidas numéricas del nivel competitivo.

5.3.2. Variables de carga competitiva

El análisis se realizó sobre una muestra común para garantizar la comparabilidad entre las asociaciones. Los juegos, sets y partidos acumulados dentro de una misma ventana presentaron correlaciones generalmente superiores a 0,98, indicando que representan prácticamente la misma dimensión de volumen competitivo. El número de torneos también mostró una relación elevada con estas medidas, aunque menos intensa, por lo que se interpretó principalmente como una medida de frecuencia de participación.

Para examinar conjuntamente esta estructura de redundancia se aplicó una agrupación jerárquica basada en la correlación de Spearman, utilizando enlace promedio (*average linkage*) y la disimilitud definida en el Capítulo 3. Como apoyo interpretativo se consideró un corte orientativo de distancia 0,20, aproximadamente equivalente a $|\rho_s| \geq 0,80$, sin utilizarlo como criterio automático de eliminación. La estructura obtenida se muestra en la Figura 5.2.




Figura 5.2: Agrupación jerárquica de las variables de carga competitiva basada en la correlación de Spearman. La línea discontinua indica el corte orientativo de distancia 0,20.

Mediante este procedimiento se identificaron grupos coherentes de variables. Los juegos, sets y partidos de la participación anterior formaron una misma familia, al igual que las medidas equivalentes de la temporada. Las variables de volumen correspondientes a las ventanas de 180 y 365 días también aparecieron estrechamente agrupadas. En cambio, la separación entre participaciones y la densidad competitiva durante los últimos 56 días conservaron un comportamiento más diferenciado.

La correlación cofenética fue de 0,957, lo que indica que el dendrograma conservó adecuadamente la estructura de distancias entre las variables [27]. Estos resultados respaldaron la utilización posterior de una única medida representativa de cada familia de carga, evitando incorporar simultáneamente variables que contenían información prácticamente equivalente.

También se analizó la relación entre la carga acumulada durante la temporada y el momento del calendario.

Sea $T_s^{\min}$ la primera fecha observable de la temporada s :

$$T_s^{\min} = \min \{T_m : \text{match_year}_m = s\}.$$

Para cada observación m , los días transcurridos desde el comienzo observable de su temporada se definieron como:

$$D_m^{\text{temp}} = T_m - T_{s(m)}^{\min},$$

donde T_m representa la fecha del torneo y $s(m)$ la temporada asociada a la observación.

Los juegos acumulados durante la temporada presentaron una asociación positiva considerable con esta variable temporal:

$$\rho_s(\text{dias_desde_inicio_temporada}, \text{juegos_temporada}) = 0,654.$$

Esta relación era esperable, puesto que los jugadores disponen de más tiempo para acumular actividad conforme avanza la temporada. Por tanto, `juegos_temporada` refleja la actividad individual, pero también está condicionada por la posición temporal del torneo dentro del calendario observable.

Por este motivo, se incorporó `dias_desde_inicio_temporada` como variable de control temporal en las especificaciones posteriores.

Tras seleccionar medidas representativas de cada familia de carga, se evaluó su colinealidad conjunta mediante el factor de inflación de la varianza (VIF), la tolerancia y los índices de condición.

Al repetir este diagnóstico sobre las variables expresadas como diferencias jugador-rival, el índice de condición máximo fue 5,750, frente a 5,614 en las cargas absolutas. Los mayores factores de inflación de la varianza correspondieron a `diff_juegos_365d` y `diff_torneos_365d`, con valores de 5,531 y 4,636, respectivamente. Estos resultados, junto

con la dependencia observada previamente entre ambas medidas, indicaron que no debían interpretarse como dimensiones completamente independientes. El diagnóstico completo de VIF y tolerancia se recoge en el Cuadro A.3 del Anexo A.2.

Por este motivo, `diff_torneos_365d` se reservó para una especificación ampliada de sensibilidad. Las restantes variables de carga presentaron niveles de dependencia compatibles con su utilización conjunta.

Dependencias no lineales entre las variables de carga

Los mayores valores de información mutua se observaron entre los juegos acumulados durante los 365 días anteriores y los juegos acumulados durante la temporada, así como entre los juegos y el número de torneos acumulados durante esa misma ventana. Estos resultados son coherentes con el solapamiento parcial entre las medidas de volumen y frecuencia competitiva identificado previamente mediante correlación.

La separación entre inicios competitivos y el número de semanas con competición durante los 56 días anteriores también apareció entre las relaciones más destacadas, lo que indica que ambas variables comparten información sobre la distribución temporal de la actividad reciente.

Como comprobación complementaria, las variables continuas se discretizaron mediante intervalos definidos por cuantiles y se calculó la información mutua ajustada (AMI). Para la estimación basada en vecinos próximos se utilizaron las dos estimaciones direccionales de cada par y su media. Asimismo, se evaluó la estabilidad de las ordenaciones utilizando diferentes números de vecinos,

$$k \in \{3, 5, 10, 20\},$$

y distintas cantidades de intervalos definidos por cuantiles,

$$q \in \{10, 15, 20, 30\}.$$

Las ordenaciones mostraron una concordancia elevada frente a estos cambios de parametrización, especialmente en el análisis basado en discretización por cuantiles. La correlación de distancias, calculada sobre submuestras reproducibles a nivel jugador–torneo, respaldó asimismo los principales patrones identificados. Los resultados más destacados de estos análisis complementarios se resumen en el Cuadro A.4 del Anexo A.2.

5.4. Información mutua respecto al rendimiento

En los predictores tradicionales, el análisis de correlación se complementó mediante información mutua con el objetivo de identificar dependencias respecto a la variable objetivo que no tuvieran que ser necesariamente lineales o monótonas.

Para la variable objetivo se empleó `mutual_info_regression`. La información mutua se interpretó como una medida exploratoria complementaria y no como una prueba aislada de relevancia predictiva.

El análisis se realizó sobre un subconjunto de 73 242 observaciones que disponían de información completa en los 47 predictores considerados.

En el porcentaje de juegos ganados, las asociaciones monótonas más destacadas se concentraron en variables relacionadas con el nivel competitivo del jugador, especialmente el ranking, los puntos ATP y la condición de cabeza de serie. Por su parte, la información mutua destacó determinadas características contextuales, como el número máximo de sets, el tamaño del cuadro, el nivel del torneo y la ronda. La Figura 5.3 resume ambos resultados.




Figura 5.3: Asociación de los principales predictores tradicionales con el porcentaje de juegos ganados: correlaciones de Spearman del jugador y variables contextuales con mayor información mutua.

Como se observa en la Figura 5.3, determinadas características contextuales presentaron dependencia respecto al rendimiento aun cuando sus asociaciones monótonas marginales eran reducidas. Por este motivo, estas variables no se eliminaron únicamente por presentar coeficientes de correlación próximos a cero.

En las variables de carga competitiva, la información mutua se utilizó para estudiar dependencias entre los propios predictores. Por tanto, dichos resultados se incorporaron al apartado dedicado a la dependencia y redundancia entre variables, y no se interpretaron como una medida de asociación con el rendimiento.

5.5. Selección final de variables

La selección final se realizó combinando los resultados obtenidos en los análisis anteriores. Se consideraron conjuntamente la asociación con la variable objetivo, la información mutua respecto al rendimiento en los predictores tradicionales, la redundancia entre predictores, las dependencias no lineales analizadas en las variables de carga, la frecuencia de las categorías, la disponibilidad de la información y la interpretabilidad deportiva.

5.5.1. Selección de los predictores del modelo base

En primer lugar, se eliminaron los puntos de ranking del jugador y del rival debido a su elevada redundancia con las posiciones de ranking. Se decidió conservar el ranking por proporcionar una representación más directa e interpretable del nivel competitivo de cada participante.

También se eliminaron categorías con una representación extremadamente reducida y una aportación estadística limitada. Entre ellas se encontraban la superficie **Carpet**, los valores desconocidos de superficie y mano dominante, la categoría olímpica y determinadas modalidades minoritarias de entrada al torneo, como **ALT**, **SE**, **PR** y **OTROS**.

Las categorías con una representación muy reducida se revisaron individualmente, sin aplicar un umbral automático de eliminación. La decisión combinó su frecuencia, su posible aportación estadística y su interpretación dentro del contexto competitivo, de modo que algunas categorías infrecuentes se conservaron cuando representaban situaciones competitivas relevantes.

Después de esta primera depuración permanecieron 32 variables predictivas. Posteriormente, se construyeron tres variables diferenciales destinadas a representar directamente la comparación entre el jugador y su rival:

$$\text{diff_ranking} = \text{ranking del rival} - \text{ranking del jugador},$$

$$\text{diff_edad} = \text{edad del jugador} - \text{edad del rival},$$

$$\text{diff_altura} = \text{altura del jugador} - \text{altura del rival}.$$

La diferencia de ranking se definió en sentido inverso al resto de diferencias porque una posición numéricamente menor representa un mejor ranking; de este modo, valores positivos de **diff_ranking** indican una posición de ranking favorable al jugador analizado.

Tras construir las variables diferenciales, se eliminaron las versiones individuales del ranking, la edad y la altura del jugador y del rival, evitando representar simultáneamente información redundante y una dependencia lineal exacta.

El conjunto final quedó formado por 29 predictores tradicionales, que constituyeron el bloque de predictores tradicionales del modelo base.

5.5.2. Selección de las variables de carga competitiva

La selección definitiva de las variables de carga competitiva se realizó combinando su asociación con el porcentaje de juegos ganados, la redundancia entre medidas, las dependencias no lineales, la interpretación deportiva y la estabilidad de los resultados en distintos periodos y contextos competitivos. En consecuencia, no se aplicó una regla automática basada en un único coeficiente.

Los juegos, los sets y los partidos acumulados dentro de una misma ventana presentaron una redundancia muy elevada. Por este motivo, se seleccionaron los juegos como medida representativa del volumen competitivo, al permitir diferenciar con mayor precisión participaciones de distinta duración.

La especificación principal se construyó mediante diferencias jugador–rival. Para una medida de carga X , la diferencia se definió como:

$$\Delta X_{i,m} = X_{i,m} - X_{r(i,m),m},$$

donde $X_{i,m}$ representa la carga previa del jugador analizado y $X_{r(i,m),m}$ la correspondiente a su rival en el mismo partido.

Se optó por utilizar estas variables relativas porque mostraron asociaciones más claras con el rendimiento y representan directamente la naturaleza comparativa del enfrentamiento. Además, no se incorporaron simultáneamente la carga del jugador, la carga del rival y su diferencia, puesto que:

$$\Delta X = X_{\text{jugador}} - X_{\text{rival}},$$

de modo que la inclusión conjunta de las tres variables introduciría una dependencia lineal exacta.

El núcleo principal quedó formado por cinco variables relativas:

- `diff_juegos_365d`, como medida del volumen competitivo acumulado durante el último año;
- `diff_juegos_temporada`, para representar la carga acumulada durante la temporada vigente;
- `diff_juegos_ultima_fecha_competitiva`, como indicador de la carga correspondiente a la participación inmediatamente anterior;
- `diff_log_dias_entre_inicios_competitivos`, para representar la separación temporal relativa entre las participaciones previas de ambos jugadores;
- `diff_semanas_con_competicion_56d`, como medida relativa de la densidad competitiva reciente.

Las variables seleccionadas representan dimensiones complementarias de la exposición competitiva: volumen anual, acumulación estacional, carga de la participación anterior, separación temporal y densidad reciente.

La variable `diff_torneos_365d` se reservó para una especificación ampliada de sensibilidad, debido a su dependencia con `diff_juegos_365d`. Asimismo, la carga estacional se mantuvo junto con `dias_desde_inicio_temporada`, incorporada como control del avance del calendario.

Como análisis de robustez, se definió una especificación equivalente de 180 días, sustituyendo `diff_juegos_365d` por `diff_juegos_180d` y utilizando `diff_torneos_180d` únicamente en el modelo ampliado.

Los análisis de estabilidad por periodo temporal, nivel del torneo y superficie respaldaron especialmente las diferencias de juegos y la separación temporal. La variable

`diff_semanas_con_competicion_56d` se mantuvo en el núcleo principal con carácter exploratorio, mientras que la diferencia de torneos se reservó como medida de sensibilidad por su mayor dependencia con el volumen competitivo.

Las variables de carga finalmente consideradas y su función dentro de las distintas especificaciones se resumen en el Cuadro 5.1.

Cuadro 5.1: Variables de carga competitiva seleccionadas para la modelización.

Dimensión representada	Variable seleccionada	Incorporación
Volumen competitivo anual	<code>diff_juegos_365d</code>	Principal
Acumulación estacional	<code>diff_juegos_temporada</code>	Principal
Participación anterior	<code>diff_juegos_ultima_fecha_competitiva</code>	Principal
Separación temporal	<code>diff_log_dias_entre_inicios_competitivos</code>	Principal
Densidad competitiva reciente	<code>diff_semanas_con_competicion_56d</code>	Principal (exploratoria)
Frecuencia competitiva	<code>diff_torneos_365d</code>	Ampliado

Nota: En la especificación alternativa de 180 días, `diff_juegos_365d` y `diff_torneos_365d` se sustituyen por `diff_juegos_180d` y `diff_torneos_180d`, respectivamente; las restantes variables permanecen sin cambios.

5.5.3. Conjuntos finales para la modelización

A partir de la selección anterior se definió un modelo base y dos familias de modelos con variables de carga competitiva, correspondientes a las ventanas de 365 y 180 días.

El modelo base quedó formado por los 29 predictores tradicionales seleccionados y la variable de control temporal `dias_desde_inicio_temporada`, por lo que incluyó un total de 30 predictores. Este control representa el avance del calendario y permite considerar

que la oportunidad de acumular actividad durante una temporada aumenta conforme transcurren los días.

Para la ventana principal de 365 días se definieron dos modelos adicionales. El modelo principal incorporó cinco diferencias jugador–rival asociadas al volumen anual, la carga estacional, la participación anterior, la separación temporal y la densidad competitiva reciente, alcanzando 35 predictores. El modelo ampliado añadió `diff_torneos_365d` como medida de sensibilidad relacionada con la frecuencia de participación, alcanzando 36 predictores.

La especificación de robustez de 180 días mantuvo la misma estructura, sustituyendo `diff_juegos_365d` por `diff_juegos_180d`. El modelo principal de esta familia incluyó 35 predictores y el modelo ampliado incorporó adicionalmente `diff_torneos_180d`, hasta alcanzar 36. El detalle de los 29 predictores tradicionales, el control temporal y las variables de carga utilizadas se recoge en los Cuadros A.1 y A.2 del Anexo A.1.

Las distintas especificaciones definidas para la modelización se resumen en el Cuadro 5.2.

Cuadro 5.2: Especificaciones definidas para la modelización.

Familia	Especificación	N.º de predictores	Construcción
365 días	Base	30	29 predictores tradicionales + control temporal
365 días	Principal	35	Base + 5 variables de carga
365 días	Ampliada	36	Principal + frecuencia competitiva (365 días)
180 días	Base	30	29 predictores tradicionales + control temporal
180 días	Principal	35	Base + 5 variables de carga
180 días	Ampliada	36	Principal + frecuencia competitiva (180 días)

La comparación entre el modelo base y los modelos con carga se realizará sobre las mismas observaciones dentro de cada familia. Para ello se conservaron únicamente partidos emparejados en los que ambos jugadores disponían del historial requerido, de la variable objetivo y de la cobertura temporal correspondiente.

La muestra de desarrollo de 365 días quedó formada por 73 250 observaciones jugador–partido, correspondientes a 36 625 encuentros y 1 176 jugadores. La muestra de 180 días quedó formada por 73 450 observaciones, correspondientes a 36 725 encuentros y los mismos 1 176 jugadores.

La temporada 2024, reservada para la prueba temporal externa, quedó formada por 5 912 observaciones jugador–partido, correspondientes a 2 956 encuentros y 369 jugadores en ambas familias.

Aunque los dos modelos base contienen los mismos 30 predictores, se estimarán de manera independiente sobre cada muestra. Por tanto, las métricas se compararán únicamente dentro de cada familia:

$$\text{Base-365} \longleftrightarrow \text{Principal-365} \longleftrightarrow \text{Ampliado-365},$$

$$\text{Base-180} \longleftrightarrow \text{Principal-180} \longleftrightarrow \text{Ampliado-180}.$$

La ventana de 180 días se utilizará como análisis de robustez y no como una comparación directa con la ventana anual, ya que ambas familias se construyeron sobre muestras diferentes.

Para garantizar la trazabilidad se conservaron un *dataset* maestro, dos conjuntos de desarrollo y dos conjuntos de prueba temporal externa, correspondientes a las ventanas de 365 y 180 días. Las variables identificativas se mantuvieron para definir las particiones temporales, pero no se utilizarán como predictores. Los pocos valores ausentes de las diferencias de ranking, altura y edad se tratarán posteriormente dentro del proceso de modelización, ajustando la imputación exclusivamente con los datos de entrenamiento.

En total, se definieron cinco conjuntos de predictores y seis combinaciones de muestra y especificación para la comparación posterior, ya que el modelo base debía estimarse por separado sobre las muestras de 365 y 180 días.

Capítulo 6

Modelización y resultados

Una vez construidas las variables de carga competitiva y seleccionados los predictores descritos en los capítulos anteriores, se desarrolló la fase de modelización. Dado que la variable objetivo, `porcentaje_juegos_ganados`, es una variable continua definida en el intervalo $[0, 1]$, el problema predictivo se formuló como una tarea de regresión supervisada.

Su objetivo principal fue evaluar si la incorporación de información sobre la carga competitiva externa observable permitía mejorar la predicción del rendimiento respecto al modelo base definido previamente, formado por los predictores tradicionales y el control temporal.

Para ello, se estableció una estrategia de comparación progresiva entre diferentes especificaciones predictivas y se utilizó una validación temporal que respetara el orden cronológico de los datos. El proceso se estructuró diferenciando la fase de desarrollo y selección de modelos de la posterior evaluación temporal externa.

En este capítulo se describe, en primer lugar, la estrategia de modelización y validación temporal. Posteriormente se presentan la comparación y selección de los modelos, la aportación incremental de las variables de carga y sus comprobaciones de robustez. Finalmente, se evalúan las configuraciones definidas sobre la temporada 2024 y se analizan la incertidumbre de las mejoras, la importancia predictiva de las variables y la coherencia de las predicciones finales.

6.1. Estrategia de modelización y validación temporal

La estrategia de modelización se diseñó para evaluar la aportación predictiva incremental de las variables de carga competitiva mediante las especificaciones Base, Principal y Ampliada definidas en el apartado anterior. Esta comparación se aplicó tanto a la familia principal de 365 días como a la alternativa de 180 días, evaluando siempre las especificaciones dentro de su correspondiente muestra.

La estrategia de desarrollo respetó el orden cronológico de los datos, de modo que cada modelo se entrenara exclusivamente con información anterior al periodo utilizado para su validación. Esta elección reproduce el escenario real de predicción temporal y evita mezclar observaciones futuras y pasadas mediante una partición aleatoria convencional [25].

Las temporadas 2009–2019 y 2022–2023 constituyeron el conjunto de desarrollo, mientras que 2024 se reservó íntegramente para la evaluación temporal externa. Dentro del conjunto de desarrollo se definieron cinco *folds* con ventana de entrenamiento creciente. En este contexto, cada *fold* representa una partición temporal formada por un conjunto de entrenamiento y un periodo posterior utilizado para validación. Se utilizaron como temporadas de validación 2017, 2018, 2019, 2022 y 2023:

Fold 1: 2009–2016 $\longrightarrow$ 2017,

Fold 2: 2009–2017 $\longrightarrow$ 2018,

Fold 3: 2009–2018 $\longrightarrow$ 2019,

Fold 4: 2009–2019 $\longrightarrow$ 2022,

Fold 5: 2009–2019, 2022 $\longrightarrow$ 2023.

La discontinuidad entre 2019 y 2022 responde a la exclusión de 2020 y al uso de 2021 exclusivamente como año auxiliar para reconstruir el historial competitivo previo, tal como se explicó en el Apartado 4.2. Asimismo, las dos observaciones recíprocas de cada partido se mantuvieron siempre dentro de la misma partición temporal, evitando dividir un mismo encuentro entre entrenamiento y validación.

Los cinco *folds* constituyeron el mecanismo de validación interna utilizado para comparar los algoritmos candidatos, ajustar sus hiperparámetros y analizar la estabilidad temporal de las decisiones y de la aportación incremental de las variables de carga.

La selección exploratoria inicial de predictores se realizó sobre el conjunto completo de desarrollo y, por tanto, no quedó completamente anidada dentro de cada *fold* temporal. Esta circunstancia puede introducir cierto optimismo en la validación interna. Para valorar su impacto, se realizó una auditoría de estabilidad recalculando en cada *fold* las principales medidas de selección únicamente con sus datos de entrenamiento. Las decisiones obtenidas reprodujeron las conclusiones principales de la selección original. Los resultados de esta auditoría se resumen en el Cuadro A.8. Aunque la limitación formal se mantiene, la auditoría no mostró evidencia de cambios sustanciales en las decisiones adoptadas. La temporada 2024 permaneció completamente excluida de todo este proceso.

La evaluación se realizó mediante MAE, RMSE y R^2 , definidos en el Apartado 3.7. El MAE se estableció como métrica principal de comparación, ya que cuantifica directamente la magnitud media del error en la misma escala que la variable objetivo y presenta una interpretación sencilla. El RMSE se utilizó de forma complementaria, al penalizar con mayor intensidad los errores de mayor magnitud, mientras que el R^2 permitió valorar el rendimiento del modelo en relación con la variabilidad de la variable objetivo y con la referencia basada en su media. De este modo, la selección no dependió de una única medida de rendimiento predictivo.

Las métricas se calcularon de forma independiente en cada uno de los cinco *folds*. La comparación de los modelos consideró principalmente el MAE medio entre las particiones, pero también su comportamiento individual a lo largo del tiempo, evitando fundamentar las decisiones únicamente en el resultado obtenido durante una temporada concreta.

6.2. Comparación y selección de modelos

Antes de comparar los algoritmos se establecieron dos referencias predictivas sencillas con el objetivo de disponer de un punto de partida frente al que valorar la utilidad real

de los modelos posteriores. La primera asignó a todas las observaciones el valor medio de la variable objetivo observado en el conjunto de entrenamiento. Debido a la estructura recíproca jugador-partido, dicho promedio fue igual a 0,5 en todas las particiones y produjo un MAE medio de 0,1119. Esta referencia permitió cuantificar el error que se obtendría sin utilizar información específica de los jugadores ni del contexto competitivo.

Como segunda referencia se utilizó una regresión lineal basada exclusivamente en `diff_ranking`, que redujo el MAE medio hasta 0,1070. Su inclusión permitió comprobar cuánto podía predecirse utilizando únicamente una de las variables tradicionales más informativas y establecer una referencia más exigente antes de incorporar el conjunto completo de predictores. De este modo, las mejoras obtenidas posteriormente podían interpretarse en relación tanto con una predicción sin información específica como con una aproximación sencilla basada en el nivel competitivo relativo de los jugadores.

Sobre el modelo base se compararon seis algoritmos representativos de diferentes niveles de flexibilidad: Ridge Regression como referencia lineal regularizada; Random Forest y Extra Trees como métodos basados en agregación de árboles; e HistGradientBoosting, XGBoost y LightGBM como algoritmos de *gradient boosting*, capaces de representar relaciones no lineales e interacciones entre predictores. Esta selección permitió comparar familias metodológicamente diferentes sin ampliar innecesariamente el número de modelos evaluados. Todos se evaluaron inicialmente mediante las mismas cinco particiones temporales y sin optimización específica de hiperparámetros. Los mejores resultados iniciales correspondieron a LightGBM y HistGradientBoosting, con MAE medios de 0,1013 y 0,1014, respectivamente. XGBoost obtuvo inicialmente un MAE de 0,1030, mientras que Ridge, Random Forest y Extra Trees presentaron errores superiores.

La comparación inicial de los algoritmos y de la referencia basada únicamente en la diferencia de ranking se resume en la Figura 6.1.




Figura 6.1: Reducción relativa del MAE respecto a la referencia basada en la media en la comparación inicial. La línea discontinua indica el rendimiento de la referencia basada en `diff_ranking`.

A partir de estos resultados, la optimización posterior se concentró en HistGradient-Boosting, LightGBM y XGBoost, manteniendo Ridge como referencia lineal regularizada. Random Forest y Extra Trees no se sometieron a una optimización adicional, ya que presentaron un rendimiento medio inferior en la comparación inicial y no aportaban una familia metodológica adicional que justificara ampliar innecesariamente el proceso de ajuste.

Una vez identificados los modelos más competitivos, se realizó un ajuste controlado de hiperparámetros utilizando las mismas cinco particiones temporales y el MAE medio como criterio principal de selección. La optimización se efectuó exclusivamente sobre el modelo base, antes de incorporar las variables de carga. Posteriormente, la configuración seleccionada para cada algoritmo se mantuvo fija al comparar las especificaciones base, principal y ampliada. De este modo, las diferencias observadas entre ellas podían atribuirse a la información añadida por las variables de carga y no a una optimización distinta de cada conjunto de predictores.

Para HistGradientBoosting, LightGBM y XGBoost se utilizó una búsqueda aleatoria sobre espacios previamente delimitados de hiperparámetros, permitiendo explorar configuraciones diversas con un coste computacional controlado. Ridge Regression se ajustó mediante una búsqueda en rejilla sobre el parámetro de regularización, dado que su espacio de optimización era considerablemente más reducido.

Los espacios de búsqueda y las configuraciones de hiperparámetros seleccionadas se recogen en los Cuadros A.6 y A.7 del Anexo A.2, mientras que el rendimiento medio de los modelos optimizados se resume en el Cuadro 6.1.

Cuadro 6.1: Rendimiento medio de los modelos optimizados durante la validación temporal interna.

Modelo	MAE medio
XGBoost	0,101135
HistGradientBoosting	0,101188
LightGBM	0,101192
Ridge Regression	0,103508

Tras la optimización, XGBoost presentó el menor MAE medio, con un valor de 0,101135, seguido muy de cerca por HistGradientBoosting y LightGBM. Las diferencias entre los tres algoritmos de *boosting* fueron muy reducidas, por lo que no puede interpretarse que XGBoost presentara una superioridad sustantiva respecto a los otros dos modelos.

Dado que el MAE medio se había establecido previamente como criterio principal de selección, XGBoost se adoptó como modelo principal para las comparaciones posteriores. HistGradientBoosting y LightGBM se conservaron como modelos de robustez, con el objetivo de comprobar si las conclusiones sobre la aportación de las variables de carga se mantenían al modificar el algoritmo utilizado.

6.3. Aportación incremental de las variables de carga competitiva

Una vez seleccionado XGBoost como modelo principal, se mantuvo fija su configuración y se evaluó la aportación incremental de las variables de carga competitiva. La comparación se realizó inicialmente sobre la familia de 365 días, enfrentando el modelo base con la especificación principal que incorporaba las cinco variables de carga seleccionadas previamente.

La incorporación de las cinco variables principales de carga redujo el MAE medio en 0,000796, lo que representa una mejora aproximada del 0,79 % respecto al modelo base. La reducción del error se observó en los cinco *folds* temporales y estuvo acompañada por una mejora de las métricas complementarias RMSE y R^2 . La magnitud del incremento predictivo fue, por tanto, reducida, aunque temporalmente consistente.

La variable `diff_torneos_365d`, reservada previamente para la especificación ampliada debido a su dependencia con el volumen anual de juegos, se incorporó posteriormente para comprobar si la frecuencia de participación aportaba información adicional. Su inclusión produjo una reducción adicional del MAE medio de 0,000568 respecto a la especificación principal, observándose una mejora en los cinco *folds* temporales.

En conjunto, el paso desde el modelo base hasta la especificación ampliada produjo una reducción progresiva del error durante la validación interna. Este resultado respaldó la conservación de las seis variables de carga en la especificación ampliada de 365 días, sin interpretar su aportación como evidencia de efectos causales individuales. La estabilidad temporal de estas mejoras se muestra en la Figura 6.2.




Figura 6.2: Reducción relativa del MAE de las especificaciones Principal y Ampliada respecto al modelo Base en cada *fold* temporal de XGBoost-365d.

Para analizar la contribución individual de las variables de carga se realizó el análisis de ablación descrito en el Apartado 3.8, tomando como referencia la especificación ampliada de 365 días. Cada variable se eliminó individualmente y el modelo se volvió a ajustar manteniendo el mismo algoritmo, hiperparámetros, observaciones y particiones temporales.

Para cada predictor retirado se calculó:

$$\Delta\text{MAE} = \text{MAE}_{\text{sin variable}} - \text{MAE}_{\text{modelo completo}}.$$

Por tanto, un valor positivo de ΔMAE indica que la eliminación de la variable aumenta el error y, en consecuencia, que dicha variable aporta información predictiva adicional dentro del conjunto completo de predictores. Un valor próximo a cero indica que su retirada apenas modifica el rendimiento del modelo. Los resultados obtenidos mediante este procedimiento se resumen en el Cuadro 6.2.

Cuadro 6.2: Análisis de ablación de las variables de carga en la especificación ampliada de 365 días.

Variable retirada	Δ MAE medio	Folds con deterioro
diff_torneos_365d	0,000568	5/5
diff_juegos_ultima_fecha_competitiva	0,000221	4/5
diff_juegos_365d	0,000182	4/5
diff_log_dias_entre_inicios_competitivos	0,000158	5/5
diff_juegos_temporada	0,000011	3/5
diff_semanas_con_competicion_56d	0,000007	4/5

Los resultados mostraron que la mayor pérdida de rendimiento se produjo al retirar `diff_torneos_365d`. También se observaron deterioros más claros al eliminar la carga de la participación anterior, el volumen de juegos durante los 365 días previos y la separación temporal entre participaciones. En cambio, retirar `diff_juegos_temporada` o `diff_semanas_con_competicion_56d` apenas modificó el MAE medio.

Estos resultados deben interpretarse como contribuciones predictivas condicionales y no como una medida de efecto causal o de importancia absoluta. Cuando varios predictores contienen información parcialmente compartida, el modelo puede compensar la ausencia de uno mediante los restantes. Por tanto, una contribución individual reducida en la ablación no implica necesariamente que la dimensión representada por esa variable carezca de relación con el rendimiento.

Como comprobación adicional, ambas variables se eliminaron simultáneamente. La especificación reducida obtuvo un rendimiento prácticamente equivalente, pero no mejoró de forma consistente al modelo completo en XGBoost, HistGradientBoosting y LightGBM. Por este motivo, se mantuvieron las seis variables en la especificación ampliada definitiva.

6.3.1. Robustez frente a la elección del algoritmo

La robustez de un resultado hace referencia a que su conclusión principal se mantenga cuando se modifican determinadas decisiones razonables del análisis. En este caso, aunque XGBoost fue seleccionado como modelo predictivo principal, resultaba conveniente comprobar que la mejora asociada a las variables de carga no fuera una característica exclusiva de este algoritmo.

Para ello se repitieron las comparaciones mediante HistGradientBoosting y LightGBM, los otros dos algoritmos que habían mostrado un rendimiento similar durante la validación interna. En ambos casos se conservaron los hiperparámetros seleccionados previamente sobre el modelo base, las mismas observaciones y las mismas cinco particiones temporales. Por tanto, los modelos no se volvieron a optimizar después de incorporar las variables de carga.

Los resultados reprodujeron el patrón observado con XGBoost. Tanto con HistGradientBoosting como con LightGBM, la incorporación de las cinco variables principales redujo el MAE medio en las cinco particiones temporales. La posterior incorporación de `diff_torneos_365d` produjo una reducción adicional del error, nuevamente presente en los cinco *folds* con ambos algoritmos.

La estabilidad de este patrón entre los tres modelos indica que la mejora asociada a las variables de carga no depende exclusivamente de la arquitectura de XGBoost. La magnitud de las diferencias continúa siendo reducida, pero su dirección se mantiene al modificar el algoritmo utilizado, aportando evidencia adicional de robustez predictiva.

6.3.2. Robustez frente al horizonte temporal

Además de comprobar la estabilidad frente a la elección del algoritmo, se evaluó si la aportación de las variables de carga se mantenía al modificar el horizonte temporal utilizado para representar el volumen competitivo previo. Para ello se utilizó la familia alternativa de 180 días definida en el capítulo anterior.

Esta comprobación no pretende determinar si una ventana de 180 días predice mejor o peor que la ventana principal de 365 días. Ambas familias se construyeron sobre muestras ligeramente diferentes y, por tanto, sus valores absolutos de error no son directamente comparables. El objetivo es comprobar si, dentro de la propia muestra de 180 días, vuelve a aparecer el patrón observado en la especificación anual al incorporar progresivamente información de carga.

Para mantener comparable el experimento, se conservó XGBoost con la configuración de hiperparámetros seleccionada previamente sobre el modelo base de 365 días, sin realizar una nueva optimización específica para la familia de 180 días. Se utilizaron las mismas cinco particiones temporales reconstruidas sobre la muestra de 180 días. La especificación principal substituyó `diff_juegos_365d` por `diff_juegos_180d`. En el modelo ampliado, `diff_torneos_365d` se substituyó por `diff_torneos_180d`.

La incorporación de las cinco variables principales de carga redujo el MAE medio en 0,000795 respecto al modelo base. La mejora se observó en cuatro de las cinco particiones temporales, produciéndose en el primer *fold* un ligero aumento del error.

La posterior incorporación de `diff_torneos_180d` produjo una reducción adicional del MAE medio de 0,000300 y mejoró el rendimiento en las cinco particiones. Considerando conjuntamente el modelo base y la especificación ampliada, la incorporación de las variables de carga redujo el error en los cinco *folds* temporales.

Por tanto, el patrón general observado con la ventana de 365 días se mantuvo al utilizar un horizonte alternativo de 180 días. Esta comprobación respalda la robustez del resultado frente a la definición temporal de la carga, aunque no implica que ambas ventanas sean equivalentes ni permite determinar cuál de ellas es superior.

Cuadro 6.3: MAE medio de las principales especificaciones durante la validación temporal interna.

Ventana	Modelo	Base	Principal	Ampliado
365 días	XGBoost	0,101135	0,100339	0,099771
365 días	HistGradientBoosting	0,101188	0,100425	0,099843
365 días	LightGBM	0,101192	0,100380	0,099808
180 días	XGBoost	0,101186	0,100391	0,100092

El Cuadro 6.3 resume conjuntamente el resultado principal y las comprobaciones de robustez. En todas las configuraciones, la especificación ampliada presentó un MAE medio inferior al correspondiente modelo base.

6.4. Evaluación temporal externa en 2024

Una vez finalizada la fase de desarrollo, se fijaron de forma definitiva los conjuntos de predictores, los algoritmos y los hiperparámetros que debían utilizarse en la evaluación final. A continuación, cada configuración se volvió a ajustar desde cero empleando la totalidad de la muestra de desarrollo correspondiente. Este ajuste definitivo permite aprovechar toda la información histórica disponible antes de 2024, una vez que las decisiones metodológicas ya habían sido tomadas mediante la validación temporal interna.

La evaluación externa se diseñó para responder a dos cuestiones distintas. En la familia principal de 365 días se utilizaron XGBoost, HistGradientBoosting y LightGBM con las especificaciones base, principal y ampliada. XGBoost actuó como modelo principal, mientras que los otros dos algoritmos permitieron comprobar si la aportación de las variables de carga se mantenía al modificar la arquitectura predictiva. De este modo, la familia de 365 días dio lugar a nueve ajustes finales: tres algoritmos evaluados sobre tres conjuntos de predictores.

La familia de 180 días tuvo una finalidad diferente. Su objetivo no era repetir nuevamente la comparación entre algoritmos, sino comprobar la robustez de la conclusión frente a una definición temporal alternativa de la carga competitiva. Por este motivo, se utilizó únicamente XGBoost, manteniendo las especificaciones base, principal y ampliada. En total, la evaluación temporal externa quedó formada por doce ajustes previamente definidos: nueve correspondientes a la familia de 365 días y tres a la de 180 días. Las comparaciones se realizaron siempre entre especificaciones pertenecientes a una misma familia y, cuando intervenían varios algoritmos, dentro de una misma arquitectura predictiva. Los resultados de los doce ajustes se recogen en el Cuadro 6.4.

Cuadro 6.4: Resultados de la evaluación temporal externa sobre la temporada 2024.

Ventana	Modelo	Especificación	MAE	RMSE	R^2
180 días	XGBoost	Base	0,099877	0,126815	0,121360
180 días	XGBoost	Principal	0,098932	0,126132	0,130804
180 días	XGBoost	Ampliado	0,098805	0,125915	0,133785
365 días	HistGradientBoosting	Base	0,100003	0,126819	0,121308
365 días	HistGradientBoosting	Principal	0,099142	0,126170	0,130277
365 días	HistGradientBoosting	Ampliado	0,098701	0,125540	0,138936
365 días	LightGBM	Base	0,099959	0,126851	0,120866
365 días	LightGBM	Principal	0,099198	0,126370	0,127511
365 días	LightGBM	Ampliado	0,098581	0,125547	0,138845
365 días	XGBoost	Base	0,099902	0,126825	0,121227
365 días	XGBoost	Principal	0,099051	0,126236	0,129371
365 días	XGBoost	Ampliado	0,098506	0,125467	0,139943

En el modelo principal XGBoost de 365 días, la incorporación de las cinco variables principales redujo el MAE de 0,099902 a 0,099051. La especificación ampliada disminuyó adicionalmente el error hasta 0,098506. Esto supone una reducción total del MAE de

0,001395 respecto al modelo base, equivalente aproximadamente a un 1,40 % en términos relativos. Las mejoras se resumen en las Figuras 6.3 y 6.4.




Figura 6.3: Reducción relativa del MAE de las especificaciones Principal y Ampliada respecto al modelo Base en la evaluación temporal externa de 2024 para la familia de 365 días.




Figura 6.4: Incremento de R^2 , expresado en puntos porcentuales, de las especificaciones Principal y Ampliada respecto al modelo Base en la evaluación temporal externa de 2024 para la familia de 365 días.

El mismo patrón se observó en HistGradientBoosting y LightGBM dentro de la familia de 365 días, así como en XGBoost utilizando la ventana alternativa de 180 días. En todas

las configuraciones consideradas, la especificación ampliada obtuvo un MAE inferior al correspondiente modelo base y presentó también mejoras en RMSE y R^2 .

Por tanto, la evaluación temporal externa reprodujo la conclusión obtenida durante el desarrollo: las variables de carga competitiva aportaron una mejora predictiva adicional respecto al modelo base. La magnitud de esta mejora fue modesta, pero su dirección se mantuvo entre algoritmos y horizontes temporales.

6.4.1. Incertidumbre de la mejora predictiva

Las diferencias de MAE observadas entre las especificaciones son de pequeña magnitud. Por este motivo, además de cuantificar la mejora puntual, se evaluó su estabilidad frente a posibles variaciones en la composición de los partidos que forman la muestra de 2024 mediante un procedimiento de *bootstrap*.

El *bootstrap* es una técnica de remuestreo que permite estudiar la variabilidad de una estimación utilizando la propia muestra observada. En este caso, se generaron 5 000 nuevas muestras de igual tamaño mediante selección aleatoria con reemplazo de los partidos de 2024. En cada remuestreo se recalculó el MAE de las dos especificaciones comparadas y se obtuvo nuevamente la diferencia entre sus errores. De este modo, se construyó una distribución empírica de la mejora predictiva en lugar de depender exclusivamente del valor calculado sobre la muestra original.

El remuestreo se realizó a nivel de partido y no de observación jugador-partido. Esta decisión resulta necesaria debido a la estructura recíproca del conjunto de datos: las dos filas correspondientes a un mismo encuentro representan perspectivas complementarias del mismo resultado y, por tanto, no deben tratarse como unidades independientes. En cada muestra *bootstrap*, cuando se seleccionaba un encuentro se incorporaban conjuntamente sus dos observaciones.

Para facilitar la interpretación, la mejora se definió como:

$$\Delta_{\text{mejora}} = \text{MAE}_{\text{referencia}} - \text{MAE}_{\text{modelo comparado}}.$$

Los resultados se muestran en la Figura 6.5.




Figura 6.5: Mejora del MAE e intervalos *bootstrap* del 95 % en la evaluación temporal externa de 2024.

Por tanto, valores positivos indican que la especificación comparada presenta un MAE inferior a la utilizada como referencia. A partir de las 5 000 réplicas se obtuvo el intervalo percentil del 95 % de esta diferencia y la proporción de remuestreos en los que la mejora fue positiva. En la configuración principal XGBoost-365d, el análisis mediante *bootstrap* confirmó la estabilidad de la mejora observada al incorporar las variables de carga. En la comparación entre el modelo base y la especificación ampliada, la reducción del MAE fue de 0,001395 y el intervalo *bootstrap* del 95 % se situó entre 0,000560 y 0,002225, permaneciendo completamente por encima de cero. Además, la especificación ampliada obtuvo un error inferior al modelo base en el 99,92 % de los remuestreos.

Las comparaciones intermedias entre el modelo base y la especificación principal, y entre esta última y la ampliada, mostraron el mismo comportamiento general. En ambos casos, los intervalos obtenidos permanecieron por encima de cero y la mejora se reprodujo en más del 97 % de las muestras generadas. Por tanto, la reducción progresiva del error observada al incorporar las variables de carga no quedó concentrada únicamente en la comparación entre los dos modelos extremos.

La comprobación realizada con la familia alternativa de 180 días produjo igualmente una mejora estable al comparar las especificaciones base y ampliada. El intervalo *bootstrap* permaneció por encima de cero y más del 99 % de los remuestreos reprodujeron una reducción del error, proporcionando evidencia adicional de robustez frente al horizonte temporal utilizado para definir la carga.

En conjunto, el procedimiento de remuestreo mostró que la dirección de las mejoras observadas en 2024 fue estable ante variaciones en la composición de los partidos evaluados. Esta estabilidad debe diferenciarse de la magnitud del incremento predictivo: las reducciones del error son modestas, pero se reproducen de forma consistente tanto en la configuración principal como en las comprobaciones complementarias. Los resultados se interpretan, por tanto, como evidencia de estabilidad predictiva condicionada a los modelos y a la muestra externa analizada, y no como evidencia de un efecto causal de la carga competitiva sobre el rendimiento.

6.5. Interpretabilidad del modelo final

Una vez comprobada la capacidad de generalización de las especificaciones finales, se analizó la contribución predictiva de las variables de carga en el modelo ampliado XGBoost-365d, utilizando `diff_ranking` como referencia tradicional. Este análisis no pretende atribuir efectos causales a las variables ni determinar cuánto modifica cada una el rendimiento de un jugador, sino estudiar hasta qué punto el modelo utiliza la información contenida en estos predictores para realizar sus predicciones.

Para ello se empleó la importancia por permutación. Este procedimiento evalúa una variable alterando sus valores y observando cuánto se deteriora posteriormente el rendimiento predictivo del modelo. Si la permutación de un predictor produce un aumento apreciable del error, significa que el modelo dependía de la información contenida en esa variable para mantener su capacidad predictiva. Por el contrario, una variación pequeña del error indica que su información puede tener una aportación reducida o encontrarse parcialmente sustituida por otros predictores.

Dado que cada encuentro está representado mediante dos observaciones recíprocas jugador-partido, la permutación se realizó a nivel de partido y preservando esta estructura por pares. Para cada predictor, los valores correspondientes a las dos perspectivas de un mismo encuentro se mantuvieron vinculados durante la reorganización, en lugar de permutarse de forma independiente. De este modo se evitó generar artificialmente combinaciones incompatibles entre las dos representaciones recíprocas de un partido.

La importancia obtenida mediante este procedimiento debe interpretarse de forma condicional al modelo y al conjunto de predictores utilizado. Dos variables relacionadas pueden sustituirse parcialmente entre sí, por lo que una importancia reducida no demuestra que una característica carezca de relación con el rendimiento. Del mismo modo, una importancia elevada indica utilidad predictiva para el modelo, pero no constituye evidencia de un efecto causal. Los resultados se muestran en la Figura 6.6.




Figura 6.6: Importancia por permutación de las variables diferenciales de carga competitiva y de ranking en el modelo ampliado XGBoost-365d.

Destacaron `diff_juegos_365d`, `diff_torneos_365d` y `diff_ranking`. Su permutación produjo los mayores deterioros de la capacidad predictiva del modelo. Resulta especialmente relevante que dos medidas de carga competitiva aparezcan en este grupo junto a

la diferencia de ranking, uno de los principales indicadores tradicionales del nivel relativo de los jugadores.

La carga correspondiente a la participación inmediatamente anterior y la separación temporal entre participaciones también produjeron un aumento del error al ser permutadas, aunque de menor magnitud. Por el contrario, la carga acumulada durante la temporada presentó una contribución reducida y la densidad competitiva de las últimas ocho semanas mostró una importancia prácticamente nula en esta evaluación.

Este patrón es coherente con el análisis de ablación realizado durante el desarrollo. Para cada predictor, la permutación se repitió 20 veces y las barras de error de la Figura 6.6 representan la desviación estándar del aumento del MAE obtenido entre dichas repeticiones. Dado que parte de la información puede estar compartida entre variables, estos resultados no deben interpretarse como una clasificación absoluta de su relevancia deportiva, sino como una medida de la dependencia predictiva del modelo respecto a cada predictor en la muestra externa de 2024.

6.6. Estabilidad de la mejora según la superficie

Como comprobación descriptiva adicional, se analizó si la mejora obtenida mediante la incorporación de las variables de carga se concentraba en una superficie concreta. Para ello se compararon el modelo base y la especificación ampliada de XGBoost-365d por separado en pista dura, tierra batida y hierba durante la temporada 2024. Este análisis se realizó una vez cerrado el proceso de modelización y no se utilizó para modificar la especificación del modelo.

La especificación ampliada presentó un MAE inferior al modelo base en las tres superficies analizadas. La mejora fue mayor en pista dura, seguida de hierba y tierra batida, aunque estas diferencias de magnitud deben interpretarse únicamente de forma descriptiva, especialmente en hierba debido a su menor número de encuentros. En conjunto, el resultado indica que la mejora asociada a las variables de carga no quedó concentrada

exclusivamente en una superficie determinada. Los resultados desagregados por superficie se recogen en el Cuadro A.5 del Anexo A.2.

6.7. Coherencia de las predicciones del modelo final

Como comprobación final, se examinó la coherencia de las predicciones obtenidas por la especificación ampliada XGBoost-365d. Esta revisión resulta relevante porque la variable objetivo está definida en el intervalo $[0, 1]$, mientras que un modelo de regresión XGBoost no impone de forma explícita esta restricción sobre sus predicciones. La relación entre los valores observados y las predicciones del modelo ampliado XGBoost-365d se muestra en la Figura 6.7.




Figura 6.7: Valores observados frente a predicciones del modelo ampliado XGBoost-365d en la evaluación temporal externa de 2024. La intensidad de las celdas representa el número de observaciones y la línea discontinua corresponde a la recta de identidad $y = x$.

Se observa una asociación positiva entre ambas magnitudes, aunque las predicciones presentan una menor dispersión y se concentran principalmente en la zona central del intervalo. En particular, los valores observados más extremos tienden a recibir predicciones más próximas a valores intermedios, mostrando una cierta compresión de la variabilidad predicha.

Todas las predicciones obtenidas para 2024 permanecieron dentro del intervalo teórico, por lo que no fue necesario aplicar ningún procedimiento posterior de truncamiento. Asimismo, se comprobó la reciprocidad entre las dos perspectivas de cada partido. Dado que el porcentaje de juegos ganados de ambos jugadores es complementario, una predicción perfectamente simétrica cumpliría:

$$\hat{p}_{i,m} + \hat{p}_{r(i,m),m} = 1.$$

La desviación absoluta media respecto a esta condición fue de 0,0034 y la máxima de 0,0193. Por tanto, aunque el modelo no incorpora explícitamente una restricción de simetría, las predicciones mostraron una elevada coherencia entre las dos representaciones recíprocas de cada encuentro.

Estas comprobaciones tuvieron únicamente carácter diagnóstico. No se aplicó posteriormente ninguna corrección, truncamiento o simetrización de las predicciones, por lo que las métricas presentadas anteriormente corresponden directamente a las salidas originales de los modelos evaluados.

Capítulo 7

Discusión

7.1. Interpretación de los principales resultados

El principal resultado de este trabajo es que la incorporación de variables de carga competitiva externa observable aportó capacidad predictiva adicional respecto al modelo base. La mejora observada durante el desarrollo se reprodujo posteriormente en la evaluación temporal externa de 2024.

En XGBoost-365d, el MAE disminuyó de 0,099902 en el modelo base a 0,098506 en la especificación ampliada, equivalente a una reducción relativa aproximada del 1,40 %. El RMSE y el R^2 evolucionaron también favorablemente.

Por tanto, la aportación de la carga debe caracterizarse como reducida en magnitud, pero consistente. Los resultados indican que las diferencias en la exposición competitiva previa entre jugador y rival contienen información predictiva que no queda completamente representada por los predictores tradicionales ni por el control temporal. Sin embargo, el carácter observacional del estudio impide interpretar esta relación como un efecto causal de la carga sobre el rendimiento.

7.2. Interpretación de la carga competitiva y relación con la literatura

Los análisis exploratorios mostraron asociaciones positivas entre algunas medidas de carga y el porcentaje de juegos ganados, especialmente al utilizar diferencias jugador–rival. Este resultado no implica que competir más produzca un mejor rendimiento, ya que los jugadores de mayor nivel pueden disputar más encuentros, avanzar más rondas y mantener una participación más continuada en el circuito.

Esta dificultad interpretativa también aparece en la literatura. Kovalchik [20] mostró que la relación entre carga acumulada y ausencia competitiva posterior puede verse condicionada por la estructura temporal y por factores de confusión. Asimismo, Reid y Duffield [24] describen alteraciones fisiológicas, neuromusculares y perceptivas asociadas a la competición, aunque la evidencia sobre su traducción directa al rendimiento posterior es limitada.

Por ello, las variables utilizadas en este trabajo deben interpretarse como indicadores de carga competitiva externa observable y no como medidas directas de fatiga. Esta distinción entre carga externa e interna es coherente con la literatura sobre monitorización deportiva [4]. En consecuencia, que `diff_juegos_365d` y `diff_torneos_365d` presenten utilidad predictiva indica que el historial competitivo contiene información adicional, pero no permite identificar el mecanismo fisiológico responsable ni atribuir causalidad.

7.3. Robustez y relevancia práctica de la mejora

La aportación de las variables de carga mostró una elevada consistencia frente a diferentes decisiones del modelado. La reducción del error se reprodujo con XGBoost, HistGradientBoosting y LightGBM y se mantuvo al sustituir la ventana principal de 365 días por la especificación alternativa de 180 días. Asimismo, la evaluación temporal externa de 2024 confirmó el patrón observado durante el desarrollo.

El análisis mediante *bootstrap* reforzó esta conclusión, ya que la mejora entre el modelo base y la especificación ampliada se mantuvo positiva en prácticamente todos los remuestreos considerados. Además, el análisis descriptivo por superficie mostró una reducción del MAE en pista dura, tierra batida y hierba, por lo que el resultado no quedó concentrado exclusivamente en un único contexto competitivo.

No obstante, esta estabilidad debe diferenciarse de la magnitud de la mejora. La reducción del error fue modesta y, por tanto, las variables de carga deben considerarse una fuente de información complementaria más que un factor dominante de la capacidad predictiva. Su interés reside principalmente en que aportan información adicional de forma consistente una vez considerados los predictores tradicionales y el control temporal.

7.4. Limitaciones del estudio

El trabajo presenta varias limitaciones que deben considerarse al interpretar los resultados. En primer lugar, la fuente de datos proporciona una fecha asociada al torneo, pero no la fecha exacta de cada partido. Por este motivo, todos los encuentros disputados por un jugador dentro de una misma competición reciben la misma carga previa y no es posible reconstruir con precisión los periodos reales de recuperación entre rondas.

En segundo lugar, las variables construidas representan exclusivamente carga competitiva externa observable. No se dispone de información sobre entrenamientos, lesiones, desplazamientos, recuperación, percepción del esfuerzo u otras medidas fisiológicas, por lo que no puede identificarse directamente el estado de fatiga de cada jugador. Además, el carácter observacional del estudio impide establecer relaciones causales entre la carga competitiva y el rendimiento.

Otra limitación metodológica deriva de que la selección exploratoria inicial de predictores se realizó sobre el conjunto completo de desarrollo y no quedó completamente anidada dentro de cada *fold* temporal. No obstante, la auditoría posterior reprodujo las principales decisiones utilizando exclusivamente la información de entrenamiento de cada

partición, sin mostrar evidencia de que esta limitación hubiera modificado sustancialmente las decisiones adoptadas.

Además, aunque la temporada 2024 permaneció completamente separada durante el desarrollo y permitió realizar una evaluación temporal externa, sigue representando un único periodo futuro. Por tanto, la generalización de las conclusiones a otras temporadas, cambios en el circuito o contextos competitivos deberá confirmarse mediante nuevas evaluaciones temporales.

Por último, el estudio se circunscribe al circuito ATP y utiliza el porcentaje de juegos ganados como medida del rendimiento. En consecuencia, no puede asumirse que la magnitud de la aportación predictiva observada se mantenga necesariamente en otros contextos competitivos o al utilizar definiciones alternativas del rendimiento, como el resultado final del encuentro.

7.5. Implicaciones y líneas futuras

Los resultados obtenidos sugieren que la carga competitiva externa observable puede considerarse una fuente complementaria de información para la predicción del rendimiento en tenis profesional. Su aportación es reducida en magnitud, pero suficientemente estable como para justificar su consideración junto con variables tradicionales como el ranking, el contexto competitivo y las características de los jugadores.

Como líneas futuras, sería especialmente relevante disponer de las fechas exactas de cada partido para representar con mayor precisión los periodos de recuperación entre encuentros e incorporar información actualmente no observable, como lesiones, desplazamientos, entrenamiento o medidas de carga interna. También resultaría de interés evaluar la estabilidad de los resultados en nuevas temporadas y estudiar si la aportación de la carga se mantiene al controlar el nivel competitivo mediante sistemas dinámicos de valoración, como Glicko, u otras formulaciones de fuerza competitiva dependientes del tiempo utilizadas en la modelización del tenis profesional [33, 13].

Otra posible línea de investigación consiste en explorar representaciones temporales más flexibles de la carga competitiva. En este trabajo se han utilizado ventanas definidas de 365 y 180 días, además de medidas de actividad reciente, pero podría estudiarse una ponderación continua en la que la influencia de la actividad previa disminuyera progresivamente con el tiempo. Esto permitiría analizar si la información predictiva de la carga presenta algún patrón temporal que no quede completamente representado por las ventanas consideradas.

Como problema abierto, resultaría de interés estudiar si la información contenida en las variables de carga competitiva se encuentra plenamente reflejada en las probabilidades implícitas del mercado de apuestas. Este análisis requeriría una formulación específica en términos de probabilidad de victoria, la incorporación de información externa sobre cuotas y un procedimiento de evaluación distinto al desarrollado en este trabajo. A partir de ello, podría analizarse si las variables de carga aportan información adicional al mercado y, en su caso, si las discrepancias observadas se traducen en rentabilidad teórica fuera de muestra.

Capítulo 8

Conclusiones

Este trabajo se planteó con el objetivo de comprobar si incorporar información sobre la carga competitiva externa observable podía mejorar la predicción del porcentaje de juegos ganados respecto al modelo base, formado principalmente por variables tradicionales disponibles antes del partido. Los resultados muestran que estas variables aportan información predictiva adicional, por lo que la pregunta principal del estudio puede responderse afirmativamente.

Entre los algoritmos evaluados, XGBoost fue seleccionado como modelo principal al presentar el menor MAE medio durante la validación temporal, aunque su rendimiento fue muy similar al obtenido con HistGradientBoosting y LightGBM. En la evaluación final sobre 2024, la incorporación de todas las variables de carga redujo el MAE aproximadamente un 1,40 % respecto al modelo base. El RMSE disminuyó también alrededor de un 1,07 %, mientras que el R^2 aumentó de 0,1212 a 0,1399, lo que supone un incremento de 0,0187, equivalente a 1,87 puntos porcentuales. Las tres métricas evolucionaron, por tanto, en la misma dirección.

La estabilidad del resultado se comprobó mediante diferentes análisis de robustez. El patrón se reprodujo con HistGradientBoosting y LightGBM y también al utilizar una ventana alternativa de 180 días. Además, en la evaluación externa de 2024, la especificación

ampliada de XGBoost-365d superó al modelo base en el 99,92 % de los remuestreos realizados mediante *bootstrap*, mientras que con la ventana de 180 días la mejora se mantuvo positiva en más del 99 % de los remuestreos.

En cuanto a las variables de carga, las diferencias en el número de torneos y de juegos acumulados durante los 365 días anteriores fueron las que mostraron una aportación predictiva más clara en el modelo final. También se observó utilidad en la carga correspondiente a la participación anterior y en la separación temporal entre participaciones. En cambio, la carga acumulada durante la temporada y la densidad competitiva de las últimas ocho semanas presentaron una contribución individual mucho menor. Estos resultados sugieren que el volumen y la frecuencia de la actividad acumulada durante el último año contienen más información predictiva que algunas de las medidas de actividad más reciente consideradas.

En conjunto, los resultados muestran que la carga competitiva externa observable no sustituye a las variables tradicionales utilizadas para representar el nivel y el contexto de los jugadores, pero sí añade información útil para mejorar ligeramente la predicción del rendimiento. Esta aportación debe interpretarse con cautela, ya que las variables construidas no miden directamente la fatiga y los datos disponibles no permiten conocer con precisión aspectos como los días reales de recuperación entre partidos. Aun con estas limitaciones, el hecho de que la mejora se haya mantenido al cambiar el modelo y el horizonte temporal, y que se reprodujera en la evaluación externa de 2024, refuerza la idea de que el historial competitivo previo contiene información que merece ser considerada en este tipo de modelos.

Apéndice A

Anexos

A.1. Definición de variables

En este anexo se recogen las variables utilizadas en las especificaciones predictivas definitivas. Se incluyen la variable objetivo, los predictores tradicionales que conforman el modelo base, la variable de control temporal y las variables de carga competitiva incorporadas en las especificaciones principal y ampliada. Las variables identificativas y de trazabilidad conservadas en los conjuntos de datos no se incluyen, al no intervenir directamente como predictores en los modelos.

Cuadro A.1: Variable objetivo, predictores tradicionales y control temporal utilizados en la modelización.

Variable	Descripción	Tipo / unidad
porcentaje_juegos_ganados	Proporción de juegos ganados por el jugador respecto al total de juegos disputados en el encuentro.	Continua, [0, 1]
tamano_cuadro	Tamaño del cuadro del torneo.	Discreta
numero_maximo_sets	Número máximo de sets previsto para el encuentro.	Discreta

Variable	Descripción	Tipo / unidad
cabeza_serie cabeza_serie_rival	Indicadores de que el jugador o su rival participan como cabeza de serie.	Binaria, 0/1
ronda_encoded	Codificación ordinal de la ronda eliminatoria. En los encuentros <i>round robin</i> toma el valor 0 y se interpreta conjuntamente con <i>es_round_robin</i> .	Ordinal
es_round_robin	Indicador de que el encuentro pertenece a una fase de competición mediante sistema <i>round robin</i> .	Binaria, 0/1
superficie_Clay superficie_Grass superficie_Hard	Indicadores <i>one-hot</i> de la superficie de juego: tierra batida, hierba y pista dura.	Binaria, 0/1
nivel_torneo_ATP nivel_torneo_ATP_Finals nivel_torneo_Davis_Cup nivel_torneo_Grand_Slam nivel_torneo_Masters_1000	Indicadores <i>one-hot</i> del nivel competitivo del torneo.	Binaria, 0/1
mano_dominante_L mano_dominante_R	Indicadores <i>one-hot</i> de la mano dominante del jugador.	Binaria, 0/1
tipo_entrada_DIRECT tipo_entrada_LL tipo_entrada_Q tipo_entrada_WC	Indicadores <i>one-hot</i> del tipo de entrada del jugador al torneo: entrada directa, <i>lucky loser</i> , clasificación previa o <i>wild card</i> .	Binaria, 0/1
mano_dominante_rival_L mano_dominante_rival_R	Indicadores <i>one-hot</i> de la mano dominante del rival.	Binaria, 0/1

Variable	Descripción	Tipo / unidad
tipo_entrada_rival_DIRECT tipo_entrada_rival_LL tipo_entrada_rival_Q tipo_entrada_rival_WC	Indicadores <i>one-hot</i> del tipo de entrada del rival al torneo.	Binaria, 0/1
diff_ranking	Diferencia entre el ranking del rival y el ranking del jugador. Un valor positivo representa una posición relativa favorable al jugador.	Posiciones ATP
diff_edad	Diferencia entre la edad del jugador y la edad del rival.	Años
diff_altura	Diferencia entre la altura del jugador y la altura del rival.	Centímetros
dias_desde_inicio_temporada	Días transcurridos desde la primera fecha observable de la temporada hasta la fecha del torneo actual.	Días

Nota: porcentaje_juegos_ganados es la variable objetivo;

dias_desde_inicio_temporada, el control temporal. Las otras 29 variables forman el modelo base.

Cuadro A.2: Definición y unidades de las variables de carga competitiva utilizadas en la modelización.

Variable	Descripción	Unidad
diff_juegos_365d	Diferencia jugador–rival en el número de juegos disputados durante los 365 días anteriores al torneo actual.	Juegos
diff_juegos_temporada	Diferencia jugador–rival en el número de juegos acumulados desde el comienzo de la temporada competitiva vigente.	Juegos

Variable	Descripción	Unidad
diff_juegos_ultima_fecha_competitiva	Diferencia jugador–rival en el número de juegos disputados durante la participación competitiva inmediatamente anterior.	Juegos
diff_log_dias_entre_inicios_competitivos	Diferencia jugador–rival entre las transformaciones $\log(1 + D)$ de la separación entre los inicios de dos participaciones competitivas consecutivas.	Adim.
diff_semanas_con_competicion_56d	Diferencia jugador–rival en el número de semanas naturales distintas con al menos un inicio competitivo durante los 56 días anteriores.	Semanas
diff_torneos_365d	Diferencia jugador–rival en el número de torneos disputados durante los 365 días anteriores.	Torneos
diff_juegos_180d	Diferencia jugador–rival en el número de juegos disputados durante los 180 días anteriores.	Juegos
diff_torneos_180d	Diferencia jugador–rival en el número de torneos disputados durante los 180 días anteriores.	Torneos

Nota: Todas las diferencias se calculan como $X_{\text{jugador}} - X_{\text{rival}}$.

A.2. Resultados complementarios

Este apartado recoge resultados exploratorios y diagnósticos adicionales, los espacios de búsqueda y configuraciones seleccionadas, así como un resumen de la estabilidad temporal de la selección de variables.




Figura A.1: Distribución del intervalo entre inicios competitivos antes y después de la transformación logarítmica.

Nota: En el panel izquierdo se representa la escala original hasta el percentil 99 para favorecer la legibilidad, sin excluir del análisis las observaciones superiores. El panel derecho muestra la transformación $\log(1 + D)$ sobre la muestra completa.

Cuadro A.3: Diagnóstico de colinealidad de las variables relativas de carga competitiva.

Variable	VIF	Tolerancia
diff_juegos_365d	5,531	0,181
diff_torneos_365d	4,636	0,216
diff_juegos_temporada	2,852	0,351
diff_semanas_con_competicion_56d	2,480	0,403
diff_log_dias_entre_inicios_competitivos	1,742	0,574
diff_juegos_ultima_fecha_competitiva	1,261	0,793

Nota: La tolerancia se calcula como $1/\text{VIF}$. El índice de condición máximo fue 5,750 para las cargas relativas y 5,614 para las cargas absolutas. Estos diagnósticos se utilizaron de forma descriptiva y no como un criterio automático de eliminación.

Cuadro A.4: Principales dependencias entre las variables de carga según medidas complementarias.

Par de variables	MI ($k = 5$)	AMI ($q = 20$)	dCor media
Juegos acumulados (365 días) – Torneos acumulados (365 días)	1,306	0,305	0,909
Juegos acumulados (365 días) – Juegos acumulados en temporada	1,374	0,158	0,642
Separación entre participaciones (log) – Semanas con competición (56 días)	0,538	0,238	0,726
Juegos acumulados en temporada – Semanas con competición (56 días)	0,522	0,175	0,630
Torneos acumulados (365 días) – Juegos acumulados en temporada	0,595	0,099	0,594
Juegos acumulados en temporada – Separación entre participaciones (log)	0,534	0,111	0,477

Nota: Se muestran los seis pares con mejor posición media en las ordenaciones de MI, AMI y dCor. Las magnitudes de las tres medidas no son directamente comparables. La concordancia media de las ordenaciones fue 0,882 al variar k y 0,988 al variar q .

Cuadro A.5: Rendimiento de las especificaciones Base y Ampliada de XGBoost-365d según la superficie en la evaluación temporal externa de 2024.

Superficie	N.º partidos	MAE Base	MAE Ampliado	Δ MAE
Pista dura	1702	0,100771	0,098798	0,001973
Tierra batida	938	0,105170	0,104735	0,000435
Hierba	316	0,079580	0,078445	0,001135

Nota: Δ MAE = MAE_{Base} – MAE_{Ampliado}; valores positivos indican un menor error de la especificación Ampliada. El número de partidos corresponde a encuentros únicos.

Cuadro A.6: Espacios de búsqueda utilizados durante la optimización de hiperparámetros.

Modelo	Hiperparámetro	Espacio explorado
XGBoost	objective	reg:squarederror, reg:absoluteerror
	learning_rate	{0,02, 0,03, 0,05, 0,08, 0,10}
	n_estimators	{100, 200, 300, 500}
	max_depth	{2, 3, 4, 5, 6}
	min_child_weight	{1, 5, 10, 20}
	subsample	{0,7, 0,85, 1,0}
	colsample_bytree	{0,7, 0,85, 1,0}
	reg_alpha	{0,0, 0,1, 1,0}
	reg_lambda	{0,1, 1,0, 5,0, 10,0}
HistGradient Boosting	loss	squared_error, absolute_error
	learning_rate	{0,03, 0,05, 0,08, 0,10, 0,15}
	max_iter	{100, 200, 300, 500}
	max_leaf_nodes	{7, 15, 31, 63}
	min_samples_leaf	{20, 50, 100, 200}
	l2_regularization	{0,0, 0,1, 1,0, 5,0, 10,0}
LightGBM	objective	regression, regression_l1
	learning_rate	{0,03, 0,05, 0,08, 0,10, 0,15}
	n_estimators	{100, 200, 300, 500}
	num_leaves	{7, 15, 31, 63}
	min_child_samples	{20, 50, 100, 200}
	reg_alpha	{0,0, 0,1, 1,0, 5,0}
	reg_lambda	{0,0, 0,1, 1,0, 5,0, 10,0}
Ridge Regression	alpha	17 valores logarítmicos entre 10^{-4} y 10^4

Nota: Para XGBoost, HistGradientBoosting y LightGBM se evaluaron 60 configuraciones mediante búsqueda aleatoria sobre cinco particiones temporales, seleccionando según el MAE medio. Para Ridge Regression se evaluaron 17 valores de **alpha** mediante búsqueda en rejilla. En las búsquedas aleatorias se fijó `random_state = 42`.

Cuadro A.7: Hiperparámetros seleccionados durante la validación temporal interna.

Modelo	Hiperparámetro	Valor
XGBoost	objective	reg:squarederror
	learning_rate	0,02
	n_estimators	300
	max_depth	6
	min_child_weight	10
	subsample	0,7
	colsample_bytree	1,0
	reg_alpha	1,0
	reg_lambda	1,0
HistGradient Boosting	loss	squared_error
	learning_rate	0,05
	max_iter	100
	max_leaf_nodes	63
	min_samples_leaf	50
	l2_regularization	1,0
LightGBM	objective	regression
	learning_rate	0,03
	n_estimators	300
	num_leaves	31
	min_child_samples	100
	reg_alpha	0,1
	reg_lambda	0,0
Ridge Regression	alpha	0,0001

Nota: En los algoritmos con componente aleatoria se utilizó una semilla fija (**random_state = 42**) para garantizar la reproducibilidad. En HistGradientBoosting se mantuvo además desactivado el *early stopping*, es decir, la detención automática del entrenamiento antes de alcanzar el número máximo de iteraciones, evitando introducir una partición interna adicional distinta del esquema de validación temporal definido.

Cuadro A.8: Resumen de la estabilidad temporal de las principales decisiones de selección.

Comprobación	Resultado resumido	Desv. estándar	Rango
Concordancia de las asociaciones entre entrenamiento y validación	0,9771	0,0075	0,9641–0,9827
Redundancia ranking–puntos ATP ($ \rho_s $)	0,9889	0,0008	0,9876–0,9896
Correlación mínima entre juegos, sets y partidos acumulados ($ \rho_s $)	0,9902	0,0002	0,9899–0,9905
Diferencias jugador–rival con mayor asociación que las cargas absolutas	100 % (30/30)	–	100 %
Dependencia juegos–torneos en 365 días ($ \rho_s $)	0,7915	0,0086	0,7796–0,8016

Nota: La desviación estándar resume descriptivamente la variabilidad entre los cinco *folds*. La cuarta fila corresponde a 30 comparaciones (6 variables $\times$ 5 *folds*).

A.3. Código empleado

El código desarrollado para la preparación de los datos, construcción de las variables, análisis estadístico y modelización se encuentra disponible en el siguiente repositorio:

`github.com/diegogarcia2003/TFG-tenis-carga-competitiva`

El repositorio contiene los nueve notebooks utilizados en el estudio, organizados según su orden de ejecución:

1. `01_preparacion_datos_atp.ipynb`: carga y unifica los archivos históricos ATP y define los bloques temporales utilizados posteriormente.
2. `02_transformacion_y_preparacion_predictores_tradicionales.ipynb`: transforma los partidos a estructura jugador-partido, construye la variable objetivo y prepara los predictores tradicionales.
3. `03_validacion_calidad_datos.ipynb`: realiza las comprobaciones de integridad, reciprocidad y coherencia temporal del conjunto de datos.
4. `04_construccion_cargas_acumuladas.ipynb`: construye las cargas competitivas acumuladas de 365 días, 180 días y temporada.
5. `05_enriquecimiento_cargas_competitivas.ipynb`: incorpora la participación anterior, la separación temporal y la densidad competitiva reciente.
6. `06_analisis_y_seleccion_variables.ipynb`: analiza y selecciona los predictores y genera las muestras utilizadas en la modelización.
7. `07_desarrollo_modelos_validacion_temporal.ipynb`: compara y optimiza los modelos mediante validación temporal y fija las configuraciones finales.
8. `08_auditoria_seleccion_temporal.ipynb`: audita la estabilidad temporal de las principales decisiones de selección de variables.
9. `09_evaluacion_temporal_externa_2024.ipynb`: realiza la evaluación temporal externa de 2024 y las comprobaciones finales de robustez e interpretabilidad.

El repositorio incluye además el archivo `requirements.txt`, con las versiones del entorno utilizado, y documentación específica sobre la estructura, ejecución y procedencia de los datos. Los notebooks se publican con sus resultados guardados, por lo que pueden revisarse directamente sin necesidad de reproducir previamente todo el pipeline.

A.4. Declaración de autoría y uso de inteligencia artificial

Yo, Diego García Alba, declaro que el presente Trabajo de Fin de Grado, titulado *Influencia de la carga competitiva acumulada en el rendimiento de tenistas profesionales*, ha sido elaborado bajo mi responsabilidad. Las ideas, datos, figuras, resultados y contenidos procedentes de otras fuentes han sido debidamente citados y referenciados, respetando los principios de integridad académica. Asimismo, declaro que este trabajo no ha sido presentado anteriormente, total o parcialmente, para la obtención de otro título académico.

Durante su elaboración se utilizó ChatGPT, de OpenAI, como herramienta de inteligencia artificial de apoyo en tareas de revisión y reformulación de textos, organización de contenidos, contraste de decisiones metodológicas, traducción y tareas técnicas vinculadas al desarrollo, revisión y depuración del código empleado en los análisis. Su uso tuvo carácter auxiliar y las propuestas obtenidas fueron revisadas, contrastadas y adaptadas antes de su incorporación. Las decisiones metodológicas finales, la ejecución de los análisis, la validación del código, la comprobación e interpretación de los resultados y la versión definitiva del trabajo han quedado bajo mi responsabilidad.

Bibliografía

- [1] ATP Tour. *ATP Suspends Tour For Six Weeks Due To Public Health & Safety Issues Over COVID-19*. 12 de mar. de 2020. URL: <https://www.atptour.com/en/news/atp-tour-2020-six-week-suspension-decision> (visitado 06-09-2026).
- [2] ATP Tour. *2026 ATP Media Guide*. 2026. URL: <https://www.atptour.com/en/media/mediaguide> (visitado 06-09-2026).
- [3] James Bergstra y Yoshua Bengio. “Random Search for Hyper-Parameter Optimization”. En: *Journal of Machine Learning Research* 13 (2012), págs. 281-305. URL: <https://www.jmlr.org/papers/v13/bergstra12a.html> (visitado 06-09-2026).
- [4] Pitre C. Bourdon et al. “Monitoring Athlete Training Loads: Consensus Statement”. En: *International Journal of Sports Physiology and Performance* 12.Suppl 2 (2017), S2-161-S2-170. DOI: 10.1123/IJSPP.2017-0208.
- [5] Leo Breiman. “Random Forests”. En: *Machine Learning* 45 (2001), págs. 5-32. DOI: 10.1023/A:1010933404324.
- [6] Roy Cerqueti, Raffaele Mattera y Valerio Ficcadenti. “Kendall correlations and radar charts to include goals for and goals against in soccer rankings”. En: *Computational Statistics* 40.4 (2025), págs. 1849-1872. DOI: 10.1007/s00180-024-01542-w.
- [7] Tianqi Chen y Carlos Guestrin. “XGBoost: A Scalable Tree Boosting System”. En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, págs. 785-794. DOI: 10.1145/2939672.2939785.
- [8] Carsten F. Dormann et al. “Collinearity: a review of methods to deal with it and a simulation study evaluating their performance”. En: *Ecography* 36.1 (2013), págs. 27-46. DOI: 10.1111/j.1600-0587.2012.07348.x.
- [9] Bradley Efron. “Bootstrap Methods: Another Look at the Jackknife”. En: *The Annals of Statistics* 7.1 (1979), págs. 1-26. DOI: 10.1214/aos/1176344552.
- [10] Aaron Fisher, Cynthia Rudin y Francesca Dominici. “All Models are Wrong, but Many are Useful: Learning a Variable’s Importance by Studying an Entire Class of Prediction Models Simultaneously”. En: *Journal of Machine Learning Research* 20.177 (2019), págs. 1-81. URL: <https://www.jmlr.org/papers/v20/18-760.html> (visitado 06-09-2026).
- [11] Jerome H. Friedman. “Greedy Function Approximation: A Gradient Boosting Machine”. En: *The Annals of Statistics* 29.5 (2001), págs. 1189-1232. DOI: 10.1214/aos/1013203451.

- [12] Pierre Geurts, Damien Ernst y Louis Wehenkel. “Extremely randomized trees”. En: *Machine Learning* 63.1 (2006), págs. 3-42. DOI: 10.1007/s10994-006-6226-1.
- [13] Paolo Gorgi, Siem Jan Koopman y Rutger Lit. “The Analysis and Forecasting of Tennis Matches by using a High Dimensional Dynamic Model”. En: *Journal of the Royal Statistical Society: Series A (Statistics in Society)* 182.4 (2019), págs. 1393-1409. DOI: 10.1111/rssa.12464.
- [14] Miguel A. Hernán y James M. Robins. *Causal Inference: What If*. Chapman & Hall/CRC, 2020. URL: <https://miguelhernan.org/whatifbook> (visitado 06-09-2026).
- [15] Arthur E. Hoerl y Robert W. Kennard. “Ridge Regression: Biased Estimation for Nonorthogonal Problems”. En: *Technometrics* 12.1 (1970), págs. 55-67. DOI: 10.1080/00401706.1970.10488634. URL: <https://www.stat.cmu.edu/technometrics/70-79/VOL-12-01/v1201055.pdf> (visitado 06-09-2026).
- [16] Francis L. Huang. “Using Cluster Bootstrapping to Analyze Nested Data With a Few Clusters”. En: *Educational and Psychological Measurement* 78.2 (2018), págs. 297-318. DOI: 10.1177/0013164416678980. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC5965657/> (visitado 06-09-2026).
- [17] Gareth James et al. *An Introduction to Statistical Learning: with Applications in R*. 2.^a ed. Springer, 2021. DOI: 10.1007/978-1-0716-1418-1. URL: <https://www.statlearning.com/> (visitado 06-09-2026).
- [18] Shachar Kaufman, Saharon Rosset y Claudia Perlich. “Leakage in Data Mining: Formulation, Detection, and Avoidance”. En: *Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2011, págs. 556-563. DOI: 10.1145/2020408.2020496.
- [19] Guolin Ke et al. “LightGBM: A Highly Efficient Gradient Boosting Decision Tree”. En: *Advances in Neural Information Processing Systems*. Vol. 30. 2017, págs. 3146-3154. URL: <https://proceedings.neurips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html> (visitado 06-09-2026).
- [20] Stephanie A. Kovalchik. “‘In search of lost time’: Identifying the causative role of cumulative competition load and competition time-loss in professional tennis using a structural nested mean model”. En: *PLOS ONE* 15.4 (2020), e0231568. DOI: 10.1371/journal.pone.0231568.
- [21] Alexander Kraskov, Harald Stögbauer y Peter Grassberger. “Estimating mutual information”. En: *Physical Review E* 69 (2004), pág. 066138. DOI: 10.1103/PhysRevE.69.066138.
- [22] Ibomoiye Domor Mienye y Yanxia Sun. “A Survey of Ensemble Learning: Concepts, Algorithms, Applications, and Prospects”. En: *IEEE Access* 10 (2022), págs. 99129-99149. DOI: 10.1109/ACCESS.2022.3207287.
- [23] Robert M. O’Brien. “A Caution Regarding Rules of Thumb for Variance Inflation Factors”. En: *Quality & Quantity* 41.5 (2007), págs. 673-690. DOI: 10.1007/s11135-006-9018-6. URL: https://www.researchgate.net/publication/226005307_A_Caution_Regarding_Rules_of_Thumb_for_Variance_Inflation_Factors (visitado 06-09-2026).

- [24] Machar Reid y Rob Duffield. “The development of fatigue during match-play tennis”. En: *British Journal of Sports Medicine* 48.Suppl 1 (2014), págs. i7-i11. DOI: 10.1136/bjsports-2013-093196.
- [25] David R. Roberts et al. “Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure”. En: *Ecography* 40 (2017), págs. 913-929. DOI: 10.1111/ecog.02881.
- [26] Jeff Sackmann. *tennis_atp: ATP Tennis Rankings, Results, and Stats*. Datos descargados originalmente del repositorio oficial `JeffSackmann/tennis_atp`, actualmente no disponible; se enlaza una copia archivística de terceros. URL: <https://github.com/Aneeshers/tennis-sackmann-archive/tree/main/atp> (visitado 06-09-2026).
- [27] Sinan Saraçlı, Nurhan Doğan y İsmet Doğan. “Comparison of hierarchical cluster analysis methods by cophenetic correlation”. En: *Journal of Inequalities and Applications* 2013 (2013), pág. 203. DOI: 10.1186/1029-242X-2013-203.
- [28] Patrick Schober, Christa Boer y Lothar A. Schwarte. “Correlation Coefficients: Appropriate Use and Interpretation”. En: *Anesthesia & Analgesia* 126.5 (2018), págs. 1763-1768. DOI: 10.1213/ANE.0000000000002864.
- [29] scikit-learn developers. *HistGradientBoostingRegressor*. URL: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingRegressor.html> (visitado 06-09-2026).
- [30] Galit Shmueli. “To Explain or to Predict?” En: *Statistical Science* 25.3 (2010), págs. 289-310. DOI: 10.1214/10-STS330.
- [31] Michal Sipko. “Machine Learning for the Prediction of Professional Tennis Matches”. MEng Computing Final Year Project. Imperial College London, 2015. URL: <https://www.doc.ic.ac.uk/teaching/distinguished-projects/2015/m.sipko.pdf> (visitado 06-09-2026).
- [32] Gábor J. Székely, Maria L. Rizzo y Nail K. Bakirov. “Measuring and testing dependence by correlation of distances”. En: *The Annals of Statistics* 35.6 (2007), págs. 2769-2794. DOI: 10.1214/009053607000000505.
- [33] Jack C. Yue et al. “A study of forecasting tennis matches via the Glicko model”. En: *PLOS ONE* 17.4 (2022), e0266838. DOI: 10.1371/journal.pone.0266838.